CF-MoA 作者研究底稿：完整实验路径、证据与论文逻辑

共同作者阅读版·由 Markdown 导出

目录

一、先建立对整个项目的共同认识 **4**
1.1 我们实际在研究什么 . . . 4
1.2 原始目标并非事后为结果发明 . . . 4
1.3 整条研究链的一页版本 . . . 5
1.4 三套编号与几个容易误解的词 . . . 5
1.5 最重要的分母与比较边界 . . . 6

二、研究前史：从医学 RAG 复现到功能关系研究 **6**
2.1 2026-08-14 起：先建立可运行的医学 QA 基线 . . . 6
2.2 85 题 world-model 路线：正向总分为何最终不足以支持机制 . . . 7
2.3 CF-WM：来源合同不满足、oracle 撤回与 gold-free 负结果 . . . 7
2.4 从 DeltaRev 到 Adapter：强信号在哪里，哪些新机制没有成立 . . . 8
2.5 09-07 原生五来源全量比较：为什么要换一个观察维度 . . . 9

三、数据：从来源收集到五类统一评测 **9**
3.1 最初要解决的问题与实际取得的来源 . . . 9
3.2 五类体系具体标什么 . . . 10
3.3 从初标、纠错到 v2/v3：为什么数字曾多次变化 . . . 11
3.4 v4 补全与 v5 抽样：完整母库和实际测试集分开 . . . 12
3.5 最终 11 来源组成与所有分母 . . . 12
3.6 系统实际看见什么，分数怎样产生 . . . 13
3.7 已证明的价值、质量边界及作者可追溯的证据 . . . 13

四、七系统与五类 head：实现、研究转向和实验证据 **14**
4.1 七个系统到底是谁，为什么存在多个“修复版” . . . 15
4.2 为什么从基线比较转向 head，而没有直接继续堆检索 . . . 17
4.3 R1：新增支持的目标，以及实际交付的组合封装 . . . 17
4.4 R2：从长审计失败，走到有作用域的三值支持执行 . . . 18
4.5 R3：为什么保留目录重决策，而没有采用更复杂的证据链 . . . 19
4.6 冻结后验证、来源暴露与七系统复用合同 . . . 20
4.7 R4：从临床机制缺失，转为给定模型下的局部干预执行 . . . 21
4.8 R5：已交付 F 的收益，与后续学习方案为何没有替换它 . . . 22
4.9 这些 head 如何给后来的 CF-MoA 提供方法基础 . . . 23

五、CF-MoA：五种操作、失败协作与完整系统验证 **23**
5.1 原问题：五个 head 怎样成为五个 agent . . . 24
5.2 建立可信起点：锁定采用版、迁移旧路由和区分验收层次 . . . 24
5.3 独立 A1：从合同不可执行到完整运行但未采用 . . . 24
5.4 新 A5 失败后为何保留 F；同工具与规则对照告诉了什么 . . . 25
5.5 互补上界：有无必要在弱新专家上继续做聚合 . . . 25
5.6 生成聚合为什么经历这么多版本 . . . 26
5.7 121 输入完整聚合结果：确实做了多专家，也确实没有胜过 B . . . 26
5.8 增量修订与四轮效果优先：从“审计过不去”走到真实质量检验 . . . 27
5.9 最简 B：保留有效能力，五操作有精确可执行含义 . . . 28
5.10 95 触发组合诊断：RCV 为什么转向选择旧候选 . . . 29
5.11 RCV 有限开发：理由有真实选择信号，也有明确误伤 . . . 29
5.12 六臂全 v5 如何闭环 . . . 30
5.13 成本、覆盖和失败分母 . . . 32
5.14 完成了什么，为什么还保留未完成项 . . . 33
5.15 复查导航与可复现边界 . . . 34

六、把实际研究变成作者共同认可的逻辑链 **34**

6.1 三个研究层次怎样连接 34
6.2 可以直接供作者讨论的一段完整故事 34
6.3 四项贡献分别有什么证据 35
6.4 哪些已有数据优先放正文，为什么 35
6.5 有吸引力且能被证据支持的写法 36

七、截至当前的完成状态、空缺与复现边界 **37**
7.1 已完成、停止和未执行分别是什么 37
7.2 为什么不同记录看起来会矛盾 37
7.3 工程与资源信息对研究结论的作用 37
7.4 作者现在可以怎样使用这些材料 38

八、证据地图：从这份底稿回到原始实验 **39**
8.1 哪些文件承担“完整工作汇报” 39
8.2 科研主记录的完整导航 39
8.3 已冻结的机器证据和定位顺序 40
8.4 这次整理本身做了什么 40

更新：2026-10-03。实验事实覆盖截至 2026-09-28 的已完成收尾；10-02/03 的工作是核验、整理和写作，没有新模型推理、评分、训练或仿真。

本文给没有参加全部实验的共同作者使用。读完应能解释项目想解决什么、材料怎样变成当前 benchmark、各方法怎样运行、为什么发展出五个 head、为什么组成 CF-MoA、哪些结果成立，以及论文可以怎样组织这些事实。它是研究材料底稿，保留尚未修饰的复杂性、负结果、版本差别和写作选择；不是正式英文论文，也不是再一份只列章节标题的 outline。

本文承担作者入组和共同写作的跨方向综合职责；原始运行事实仍以数据、方法和研究主记录及其冻结制品为准。本次建立这份文件，是因为此前论文框架主要回答“文章如何组织”，尚不能独立回答“整个项目究竟做了什么”。本文不替代原记录，不把旧计划中的“下一步”自动当作当前待执行指令。

阅读导航： 共同认识 ·研究前史 ·数据与分类 ·七系统与五 head ·CF-MoA 全流程 ·论文逻辑与数据取舍 ·完成状态与边界 ·证据地图

一、先建立对整个项目的共同认识

1.1 我们实际在研究什么

项目研究的是：医学问题中的某个条件变化后，模型怎样据此处理支持关系并回答当前问题。变化可能是病人某项证据被加入、既有用药条件失效、候选诊断的相对支持发生变化、一个已知动态模型受到干预，或者题目出现与目标无关的扰动。合格系统既要在应改变时作出改变，也要在不应改变时保持正确；“答案变化了”与“答案应该变化”不是一回事，“两次回答相同”也不等于“两次都正确”。

这里的反事实研究范围包含源作者提供的条件改变、对照、干扰与稳健性任务，并非所有记录都是具有完整结构因果模型的严格因果识别问题。因此，本研究的统一入口是**变化对具体判断的功能关系**。五类功能标签使不同来源的题目能够按共同问题观察，同时保留各来源原有题面、选项、证据和评价任务。

例如，一个治疗问题原有两条独立适用理由，变化只撤销其中一条，答案可能应当保持；一个病例增加了某疾病的支持证据，也不一定足以推翻当前最优诊断。只按“gold 翻转/不翻转”分组会把这些细节混掉。本项目先建立五类关系与 benchmark，再观察通用和医学 RAG 系统对这些关系处理得如何，随后将最有用的专门操作组织成系统。

1.2 原始目标并非事后为结果发明

09-08 的原始用户方案明确提出：“从已有医学 benchmark 中提取 CF 问题，以五种可解释的功能关系重新标注，揭示按数据集名称看不到的失败模式。”同时要求“保留原题，增加标注，不重写原 benchmark”和“不同任务保留不同评分，但可以共享标签”。这些要求解释了为什么数据贡献、taxonomy 和原生评价合同应当在作者讨论中居于核心位置。

09-21 的五 agent 计划把问题推进到系统层：当前合法输入经操作路由，由专家提出证据和答案，再产生原生输出；专家按“补支持、撤支持、比候选、算后果、抗干扰”分工。原计划允许共享权重和异构内部实现，也确实希望证明多专家证据聚合的额外作用。后来的实际实验没有稳定证明全局生成聚合更优，因而最终采用稀疏的能力路由组合。**原设计目标、真实尝试与最终采用实例是三件不同的事，本文都保留。**

原请求短引、会话行号、原 09-21 计划和 09-23 修订快照见研究路径审计及五 agent 审计。原计划是研究史证据，不取代今天的实际代码与结果。

1.3 整条研究链的一页版本

环节	实际完成的工作	对后续环节的意义
方法与运行前史	复现医学 QA/MedRGAG；探索 WM、CF 修改和 paired Adapter；有正结果，也有被强对照推翻的机制主张	学会区分系统得分、额外资源和真正机制；输入权限必须明确
来源收集	登记 26 候选资源，取得 15，归档 55,991 比较记录	建立跨来源材料库，不能把取得量直接当可评题量
五类功能体系	围绕 change、target 和关系依据标注 R1–R5，允许多标签	把 “哪个来源表现差” 细化为 “什么功能需求容易失败”
benchmark 构建	全量资格处理得到 38,123 可评单元、77,781 判断；v5 选 6,104 单元、13,000 判断，来自 11 来源	形成当前可追溯、可执行的共同评价范围
七系统诊断	M0/M2/M3/M4/M5/M6/M7 各完成 13,905 输入、15,616 评分映射	验证问题具有跨配置意义，并保留各类别差异
功能 head 研发	R1–R3 有七系统 21 组净增；R4 形成给定模型的受限执行分支；R5 采用 F 并保留后续负结果	形成可明确调用的操作能力，成熟度和验证范围不相同
五角色 CF-MoA	统一角色合同、能力路由、原生读出；尝试过独立新专家和真实多专家聚合，最终采用五操作 B	将已有有效能力组成可复现系统，解释为何采用特定组合
全量系统闭环	双骨干完整 v5 六臂，B 相对对应 MedRAG 总体 +10.09/+12.01pp，保持/应变亦改善；完成区间、来源、格式和成本收尾	支撑当前系统结论，同时指出最终独立确认尚未完成

这条链既包含真实顺序，也包含作者对研究动机的归纳。实际过程有并行开发、回退和重新审核，不是一次预注册后毫无调整的流水线。下文先讲真实路径，再单独提出论文论证与数据取舍。

1.4 三套编号与几个容易误解的词

名称	在本项目中的准确含义
R1–R5	离线功能关系标签/评测分层，允许重叠，不是输入给模型的类别提示
head	主系统末端或特定能力分支的可调用处理模块；可含提示、取分、规则、求解器和读出，不一定是训练出的神经网络头
A1–A5	CF-MoA 中的五个功能 agent 角色；五角色不等于五套独立权重，A1/A2 当前共享一次规则执行
M0/M2/M3/M4/M5/M6/M7	当前 v5 七个系统配置；M4/M5 为同一 MedRAG 方法的两种骨干/输出配置，所以是六方法家族
数据来源 M01、M02 等	来源目录编号；例如来源 M02 是 MedPIC-Bench，和系统 M2 MedRGAG 不是同一个编号体系
B / strong_B	CF-MoA 已经采用的五操作核心，身份为 `adopted_B_five_operations_v1`；后期被拿来当强基线，并不表示它没有系统贡献
F	已采用的任务适配采样/共识读出组件；是 A5 内部路径，不能把 “F 关闭” 的后来额外重答开关误读成旧 F 整个被移除

名称	在本项目中的准确含义
C0–C5	后期完整 v5 对照臂的简写；B 对应采用核心，C2 候选无理由验证，C3 有理由验证，C4 增三次回答，C5 联合选择；详见 CF-MoA 篇
RCV	后期候选验证扩展，针对固定候选池进行重新选择；不等于整个 CF-MoA
baseline / 原方法	必须绑定具体阶段、代码版本和配置；历史 “原 M4” 与结构修复后的正式 M4 可能不同
unit / judgment / input / mapping / family	比较单元、具体目标判断、去重可见输入、评分映射、依赖家族；数量不同，不能交替作分母
frozen / 新来源 / held-out	冻结只说明某时点后配置被固定；后来若根据该批结果再调优，新版本不能继续把该批称为未见验证
新运行 / 复用 / 离线重算	分别是重新调用模型、复用完全相同合法请求的已有输出、重汇总既有评分；三者都可有价值，费用和证据身份必须区别

1.5 最重要的分母与比较边界

当前 v5 的 6,104 单元展开为 13,000 入选判断，运行时为 13,905 个去重输入及 15,616 评分映射。ALL 不是简单地把 “正确输入数” 除以 13,905：主分数先在规定单元内对非 reference 原生目标取平均，再对单元等权。原题与变体的两端均正确是另一组 pair 指标。看到 8,924 个正确输入与 58.2924% ALL 并不矛盾，它们衡量不同对象。

同样，R1–R3 合计 3,678 次类别成员关系，只有 2,941 个唯一单元。R3 全包含在 R1 内，因此不能说我们在三个独立测试集上得到 21 次独立复制。R4 的 288 个模型执行问题来自 24 个 profile，不可替换当前 13 个临床 R4 单元；R5 的 208 个历史组件单元也不能与完整 3,600 个 v5 R5 单元加起来称新 benchmark。

当前结果最稳妥的读法是三层：**七系统基线和末端 head 广度证据；两个 MedRAG 骨干的完整 CF-MoA 系统证据；各 head 在新来源、规则探针或给定模型中的组件证据。**三层互相补充，各自范围不互相冒充。

二、研究前史：从医学 RAG 复现到功能关系研究

前史不是当前主结果的额外测试集，但它解释了几个重要选择：为什么不把方法起名后就直接归因于新机制，为什么不用旧 paired 高分替代当前原生评测，为什么后来的 head 需要简单而有区分力的对照。以下按已执行证据回顾；历史编号只在各自实验内有效。

2.1 2026-08-14 起：先建立可运行的医学 QA 基线

项目最初面对 MedRGAG 论文及公开代码。公开发布材料足以完整运行 Direct Response 行，但不足以一键精确复现 Table 1 全部方法：部分检索材料、精确语料/index 版本、GPT 快照和配置缺失，代码也有占位路径与接线问题。真正完成的直接回答复现覆盖 7,663 题，包含 MedQA-US 1,273、MedMCQA 4,183、MMLU-Med 1,089、PubMedQA 500 和 BioASQ 618。

按发布代码解析规则，宏平均为 65.38%，对应论文 66.64%；严格答案解析宏平均为 63.87%。严格解析与宽松发布解析不同，422 条输出不能提取单一合法选项，其中不少输出被 512-token 上限截断，但发布解析的宽松正则和回退仍把部分算对。又按论文附录的另一套提示/temperature 做了完整敏感性运行；两个配置必须分别保留，不能挑较高列冒称同一次严格复现。

后续建立的 all-Llama MedRGAG 是本地变体：将所需生成、筛选和 reader 角色放在本地 Llama 链条上，以便实际运行与调试。它继承 MedRGAG 思想和记录下来的流程，但不同于原论文混合 GPT/Llama 设置。早期 full-v1 曾在 selection 质量检查停止，没有完成后续全部阶段；随后 v15 和后来的原生任务运行具有自己的完成证据。“有一个旧失败版本” 与 “以后没有完成可运行基线” 不能混淆。

证据：复现主记录、MedRGAG 方法记录。具体复现表、解析差异及中止边界在归档原文中保留。

2.2 85 题 world-model 路线：正向总分为何最终不足以支持机制

早期尝试用状态、动作和 transition cards 组织医学推理，再让 reader 读卡片或 planner 排序。85 题上曾看到原 v15 为 60/85、带裁决 cards+planner 为 69/85，看起来有明显提升。然而审阅者实际是模型代理，不是真人，制品一直标记 `human_validated=false`。

为区分卡片结构与上游直接判断，之后真实执行了去 planner、仅 planner、普通额外推理、盲 direct-Luna 排序和同 reader 控制。完整卡片无 planner 为 66/85，仅 planner 为 70/85，盲模型直接排序 74/85，给同一 Llama reader 读该排序后 71/85。表面上叫 “world model” 的路径并没有超过更简单的直接排序。

最后进一步逐题匹配输入 token、提示外壳和解码，并把 170 个条件输入去重为 128 个实际不同 prompt，保证 42 对相同提示共享同一输出。干净 matched 结果为直接排序 64/85、WM 排序 64/85；1 题修复、1 题误伤、83 题不变。由此停止了当前实现的 WM 增益主张。中间几次非确定性或不一致输出也保留在记录中，最终结论来自干净匹配版本。

这段历史留下的研究经验很具体：完整系统高于弱基线，不足以证明 “结构” 带来额外贡献。后来的目录单次控制、R2 恒 None、F 普通多数票，以及 CF-MoA 的强旧 B 对照，都是在回答同类归因问题。证据：WM 最终匹配与停止结论，尤其原文 3190–3255 行；原冻结 summary 与代码路径在该文可追溯。

2.3 CF-WM：来源合同不满足、oracle 撤回与 gold-free 负结果

随后将问题转到反事实数据。第一轮 Gate A 冻结 6,577 条输入/gold，但源材料不足以满足当时研究计划：例如 MedPIC 缺官方 linked-pair map，CLIR 若干任务缺可用历史观测及 Full-TS，部分来源授权不清。该轮是数据/协议检查后停止，不能当作已经跑过模型的负结果。

后来 balanced60 试跑完成，但只满足 1/4 个冻结推进条件。曾称 M12 为 transition oracle，后查出构造 cards 时读取 gold/correct candidate，故明确撤回为无效 label oracle。其 30/60 不能作为机制上界或方法成绩。修正版换成完全不读 gold 的 teacher-transition，并保留原错误及修复历史。

修正版最初抽 320 题，来自 MedPIC、CLIR、MedEinst、MedCounterFact 各 80。dry start 暴露合同和 parser 缺陷；17 个触发调试或配对关联样本在接触正确性之前被排除，最终分析 303 题。因此它是 gold-unseen 的修正版分析，不能称为完全未接触的纯盲 held-out。13 臂产生 3,939 预测，所有方法保留同一最终 ID 集，失败计入分母。后检发现 326 条 MedEinst 方法输出复制占位字符串，被统一记为无效且没有看分后重生成。

结果是完整 transition 20.8%，低于本地 MedRGAG proxy 31.7%、直接排序 30.7%、无 transition 结构控制 27.1% 和等 token 推理 26.7%；shuffle 控制反而优于完整 transition。模型裁判对 100 张卡、1,567 个 claim 的检查也发现引用与支持不足。这条路线没有建立独立 world-model 效果，后来转向更局部、更容易验证的分数和支持操作。

证据：CF-WM 归档与撤回说明。修正版报告从 Git 提交 `b714735` 恢复，同名当前 `results/`

`summary.md` 后来已被 DeltaRev 使用，所以不能只按文件名读今天的内容倒推历史。

2.4 从 DeltaRev 到 Adapter：强信号在哪里，哪些新机制没有成立

这一系列主要使用 MedEinst 配对病例及构造的四选项诊断协议。开发/校准资料反复复用，各次提交不是相互独立的复制；也不是后来 v5 的独立原生输入合同。

路线	规模与实际尝试	结果与为何转向
DeltaRev	40 开发 + 160 测试配对；抽变化、找决定性证据、选择性修订	LLM-only delta 200/200 合同失败；保守路由几乎不改答，测试 0 修复/0 误伤；未支持有效选择性修订
DeltaRank	300 开发 + 300 测试；四选项分数和残差	base45.33%，残差仅 +1.0pp，5 修复/2 误伤；提供小信号但不是强机制结论
CFShift	800 开发 + 200 校准 + 500 后续配对；变化分数与疾病 Profile	Profile 信号强，纯 shift 额外 +0.2pp 且区间跨 0；不能把 Profile 全部收益写成 shift 机制
CF-KADS-MoE	复用 800/200，再 1,000 配对；学习融合	Profile77.7%，融合 78.5%，+0.8pp 未确证；MedPIC 迁移为负
RiskRoute-CF	复用 800/200，另 1,000 测试；风险路由	router73.3% 低于 Profile74.3%，未改善风险—准确率取舍
CF-Residual Adapter	400 开发 + 150 校准 + 500 后续配对；Profile、CPG 与基础选项分数线性融合	跨两接口大幅提高；基础系统的额外协同贡献未获支持，详情如下

Profile 把患者变化与 DDXPlus 疾病特征关联起来；CPG 利用编辑前后选项似然的变化。Adapter 是额外取分特征与监督线性系数的融合，不是训练整个大模型。MA 版本 9 维、MedRGAG 版本 7 维，without-base 版本 4 维，开发标签用于拟合，校准集选择正则；推理时使用冻结系数。

500 对四选项协议的关键结果如下：

配置	trap 准确率	pair 两端均正确	解释
MA-RAG 原接口	39.2%	17.6%	此处是旧配对协议下的基线
MA-RAG pair prompt	50.2%	30.2%	直接看配对已有收益
Profile-only	79.4%	42.8%	显示额外 Profile 资源贡献很强
MA-RAG + Adapter	80.0%	52.6%	相对原接口 +40.8pp
Adapter without MA-RAG	81.8%	55.0%	没有证明 MA-RAG 融合协同
MedRGAG-style 原接口	40.8%	17.6%	本地接口，不是论文原配置
MedRGAG + Adapter	82.4%	47.0%	相对原接口 +41.6pp
Adapter without MedRGAG	81.8%	46.8%	再次显示 sidecar 本身很强

without-base 是分别训练的另一组融合系数，不是把同一冻结模型某个输入即时归零。MA 版本相对 without-MA 差 −1.8pp 的区间跨 0，不等于已证明 MA-RAG 稳定有害。另一方面，shuffle delta/Profile/CPG 明显降低得分，说明这些信息确实被利用，不能因为没有协同就把全部 Adapter 成果抹掉。

旧协议允许读取 control、trap、delta，并构造受控四选项；当前 v5 每个端点独立回答，开放诊断不能按 gold 添加候选。因此旧 80% 以上成绩不能搬进当前主表。当前 R3 可以继承“有限候选取分”的思路，但候选、可见信息、参数和证据都要按新合同重新定义。证据：连续方法归档、Adapter 实现与结果、当前适用性分析。

2.5 09-07 原生五来源全量比较：为什么要换一个观察维度

接下来完成三方法 M0/M1/M2 各 25,280 唯一输入，合 75,840 预测、82,131 条方法 × 评分记录。M0/M1 各保留 5,832 已有预测，补 19,448；M2 已经完成的整条上游链原字节复用。五来源为 MedEinst、MedPIC、CPV-MedQA、Cultural Cues、MedCounterFact，另有冻结 60 对四选项敏感性协议。

原生指标显示明显异质性：MedEinst canonical match 为 M0 10.93%、M1 7.75%、M2 8.26%；MedPIC exact-set 为 35.97%、36.83%、30.84%；CPV 准确率为 61.59%、63.78%、67.09%；Cultural 为 62.53%、61.53%、66.13%；MedCounterFact EA 为 66.31%、61.87%、66.50%。M2 并非在所有来源都提高。某个方法的原题到变体 drop 较小，也可能因为它两端都较差，不能自动称更可靠。

这些结果首先证明原生流程可以完整运行，同时提示“按来源看分数”仍不足以解释功能失败。后来的 R1–R5 分类是进一步把不同来源中的支持增加、撤销、候选变化、后果推导和保持需求抽出来。这个转向与 09-08 用户的原始五类方案一致，不是看最终 B 哪个类别好才重新标注。

证据：原生全量比较，原文 1893 行后的完成表、原生评分、配对效果和复用账；这些 25,280 输入与当前 13,905 输入是不同阶段，不能求和作为当前每方法测试规模。

三、数据：从来源收集到五类统一评测

本篇解释数据工作实际做过什么、为何这样做及其限制，供未参与实验的作者共同使用。这里的“反事实”包括患者条件改变、题内假设、证据干扰和知识编辑等来源任务；它们并不都等价于可识别的个体临床因果效应。R1–R5 是五种判断功能的标签。M01–M26 是数据来源编号，与实验方法的 M0、M2 等编号是两套命名。一个“比较单元”通常是一条实际变体及其来源参照关系；“判断”是其中某个具体目标；“输入”才是一次可供系统作答的问题。这三个层次贯穿后续统计。

3.1 最初要解决的问题与实际取得的来源

项目在这轮数据工作之前，已做过五来源直接回答、初始检索和 MedRGAG 对照，每方法 25,280 个输入。2026 年 9 月 8 日的新要求是按五类方案收集医学反事实任务，优先复用已有原件，把综合 benchmark 中可定位的医学反事实子任务也纳入，同时保留其原任务。原有资源分散在诊断变化、人口属性、检索干扰、假设证据和知识编辑中，只按来源名称汇报，难以解释模型面对“新支持”“旧依据失效”等不同要求时的表现。因此需要先明确变化影响的判断，再建立可追溯的跨来源评测。原始需求及阶段 1

最初仅形成 358 单元试点，用户指出覆盖不足后扩大收集。最终登记 26 个候选来源，实际取得其中 15 个：14 个文本来源，另一个只有缺图的多模态元数据。下表列出全部候选，数量是归一化归档单元，不是最终测试题数；“未取得”只陈述当时缺口，不表示科学上排除该方向，也不表示今天仍未发布。该目录没有证明检索穷尽全部文献。FairMedQA 与 AMQA 属同一来源沿革，不能算两个来源。来源收集记录

来源编号与名称	归档单元	当时取得状态及最终去向
M01 MedEinst	5,383	已取得；有合格目标进入 v5
M02 MedPIC-Bench	183	已取得；有合格目标进入 v5
M03 MamaBench	0	未取得：gated 病例未取得
M04 肿瘤临床 CF 评测	0	未取得：未定位原病例发布包
M05 临床检验因果推理评测	33	已取得；新答案需人工/rubric，未入 v5

来源编号与名称	归档单元	当时取得状态及最终去向
M06 HIV 治疗因果情景研究	20	已取得；有合格目标进入 v5
M07 CLIR-Bench	0	未取得：指定 CF 编辑对未发布于所检树
M08 ECG-Expert-QA	0	未取得：MCo 固定文件未定位；MC 不能替代
M09 GenMedicalEval	0	未取得：仅栏目文档示例，未取得声明的 12000 条
M10 CPV-MedQA	10,225	已取得；有合格目标进入 v5
M11 Counterfactual Cultural Cues	1,349	已取得；有合格目标进入 v5
M12 FairMedQA/AMQA	4,806	已取得；有合格目标进入 v5
M13 MedEqualQA	0	未取得：所检作者仓库未发布题库
M14 DiversityMedQA	6,296	已取得；有合格目标进入 v5
M15 CLIMB	0	未取得：未取得固定诊断 CF 病例对
M16 EquityMedQA	323	已取得；新答案/rubric 不足，未入 v5
M17 MedPerturb	3,759	已取得；有合格目标进入 v5
M18 DeVisE	0	未取得：仅生成代码，受限 MIMIC 病例未取得
M19 MedFuzz	0	未取得：未取得完整固定攻击输入 release
M20 MedCounterFact	809	已取得；有合格目标进入 v5
M21 MediEval	0	未取得：受限患者上下文/知识源未取得
M22 MedRGB	3,680	已取得；有合格目标进入 v5
M23 BioRAB	12,615	已取得；有合格目标进入 v5
M24 MedCF	4,013	已取得；未执行原生知识编辑，未入 v5
M25 MedMKEB	2,497	取得编辑元数据；必需图像缺失，未入 v5
M26 COLLECT	0	未取得：受限图像包未取得

这里 M07 的缺口特指本轮要求的 CLIR 反事实编辑对；前史曾使用 CLIR 的其他观测子任务，两处说的是不同资源单元，并不矛盾。

归档共 55,991 单元，其中 53,494 是文本比较，2,497 是 MedMKEB 缺图元数据。来源发布行数不能直接相加：重复模型评价块不增加题数，MedPIC 的 284 条普通参照不增加 183 条反事实题，MedCF 的训练/验证编辑不能冒充测试编辑，无实际文字变化的记录另有处置。归档也不是一组独立患者：同一 MedQA 母题可在多个来源重用，同根多个变体、同一研究的多个问句或同一前提的多个假说相互关联。

取得之后另做来源真实性审计：核对 26 个候选的论文—作者—发布入口，15 个取得来源的 55,991 归档记录与 28,243 分析成员均保留来源对应；25 个使用的原文件涉及 38 次缓存比较，其中 36 份文件来自独立下载快照。审核还单查共享原题、无变化参照和 MedPIC 的 284 条普通参照。其通过含义是本地材料忠实于发布物，不是原作者医学答案均正确；缺失图像也没有被记成已验证。这些是历史已完成的核查，本篇没有重新下载全部来源。来源真实性审计收据

3.2 五类体系具体标什么

五类描述“这次变化对这个判断提出什么要求”，不是五个训练出的分类器，也不要求互斥。下列例子均解释已经保存的判定，不是本篇新增病例或新实验；尤其 R4 的 LabTest 例子有分类意义，却没有进入最终 v5。

功能	通俗定义与必要边界	留存具体实例
R1 新增支持	新信息确实给某项判断增加此前没有的依据；相容支持不等于足以确诊。	MedEinst `case_10000:review_target_0` 新增呼气哮鸣，支持支气管炎候选；不能据此宣称唯一诊断。
R2 撤销支持	可指出原先哪条依据，以及它为何明确失效；撤掉一条理由不等于所有风险消失。	DiversityMedQA `GenderDataset.csv:row169:source852` 将男孩改成女孩，撤销支持 Lesch–Nyhan 的一条人口学依据；其他表现仍在。
R3 重新比较	至少两个可识别候选，其相对支持因变化需要重估；答案翻转本身不构成证据。	MedEinst `case_13249:review_target_1` 将自发性气胸史替换为深静脉血栓史，影响气胸与肺栓塞的比较。
R4 推导后果	改变前提后，经有依据的关系推断尚未直接给出的结果。	LabTest `question_41:review_target_0` 询问从未使用 fenofibrate 时 HDL 是否仍为 77.6；标签不提供精确反事实数值。
R5 保持判断	有实际变化，但有理由认为某个指定目标应保持；相同答案不是充分判据。	CPV-MedQA `medqa_00001:variant_02` 改变族群描述，化疗及耳毒性证据保持，所问药理机制应保持。

定义、正例与已纠正反例

标注先确认原生问题和比较轴，再对照全部相关上下文，记录 `change`（谁的什么条件改变）、`target`（具体判断）、`labels`、`rationale/evidence`（关系及原文定位）和 `cannot_infer`（不能扩大推出的结论）。官方没有配对，就不能擅自拼一个参照；题内“不治疗会怎样”与外部人口属性变化是不同轴。删除“有症状”不等于明确“无症状”，社区讨论疾病不等于亲属确诊，新增相关信息但最终答案恰好相同也不自动成为 R5。标注合同和比较轴

先判子目标，再取父单元标签并集。例如 `case_10000` 的一个目标是新增哮鸣支持支气管炎，另一个目标是急性喉炎与支气管炎的重新比较，因此同一单元可有 R1/R3；原喉部描述不再出现，仍不足以加 R2。MedPerturb 的就诊、管理与资源需求三个任务也必须分别判定，不能把前两者的标签自动传给第三者。“关系成立”“可以按当前任务评分”“作者答案可靠”“系统答对”是四个不同问题。

3.3 从初标、纠错到 v2/v3：为什么数字曾多次变化

首轮将若干大来源限为 2,500 单元，冻结 28,243 单元、80,910 个判断；其中含 2,497 缺图元数据。用户允许适度缩减，但 2,500 是助手选择，没有统计功效或代表性证明。审阅方式实际为 603 单元逐项语义审阅、13,464 分组语义审阅、14,176 结构核验；分组共读不等于为每份病例重新做临床诊断，记录没有宣称临床专家验收。

审核确实发现了错误。初始固定抽查 88 个判断，再按发现的规则扩查 99 个，共 187 个：83 支持、92 明确问题、3 待复核、9 原参考待核。目的扩查集中检查疑似问题，不能把这个比例当全库错误率。随后修改 172 个判断、涉及 130 单元：临床类 129 项、AMQA 30 项、原参考相关 13 项；149 项撤下缺乏依据的标签，23 项保留或重新确定标签，另有 11 个原参考禁用评分。两轮涉及 252 个不同判断，不能直接把 187 与 172 相加。实际修改及前后证据

典型错误是把“夜间更难呼吸”读成“比患者过去更重”，或把原病例已有的夜间症状当新支持。AMQA 的 NBT 检测问题原已明确所问功能，新增泛称遗传病家族史并不改变检测—功能关系，于是从泛化的 R1 改为具体目标的 R5。另一些目标确实应保持，但作者 gold 有问题，正确做法是保留语义标签、单独禁用参考评分，不能直接改写原答案。更早还有一轮 704 个 AMQA 单元的可实施性裁决修正，与上述 172 个判断范围有重叠、单位不同，不能相加。复审确认这 172 项标签处

置已解决，不等于全库 gold 已验证或所有质量问题清零。

9 月 9 日的 v2 是一次明确收窄：选择文本且已有固定规则可评分的 2,015 个 R1–R4 单元，再加入 CPV 全部 1,090 个合格 R5，得到 8 来源、3,105 单元、4,872 输入、每方法 6,030 评分映射。155 个需要人工/模型裁判的候选及 106 个必要图像缺失候选未纳入；开放诊断若有既定匹配规则仍可使用，并非一概排除开放回答。v2 五类可重叠，数量为 1,929/77/327/13/1,090。v2 的实际纳入规则

同日 v3 仅调整展示分组：按 v2 调整前固定类别数，将 328 个重叠单元分给其已有类别中最小的一类。由此得到互斥的 1,601/77/324/13/1,090，总数仍为 3,105；题目、gold、原始语义和单题正确性均未变。这解释了部分历史类别分数变化并非模型进步。后续 v4/v5 恢复完整多标签语义，不能沿用 v3 的互斥字段覆盖母库。v3 的 328 项归属调整

3.4 v4 补全与 v5 抽样：完整母库和实际测试集分开

用户随后要求补齐遗漏、复用已审 R5，不能靠数量裁剪冒充完成。9 月 10 日固定了 24,436 个抽样遗漏单元，最终其中 18,023 有合格目标；其余已记录依据不足、构造无效、五类外或评分资格问题。另复用 18,238 个旧 R5 的语义，重新判断执行资格，恢复 16,972 单元；这不是 18,238 次新标注。MedPerturb 又补 3,615 个此前遗漏的 RESOURCE 判断，3,529 个合格，并使 3 个父单元重新获得至少一个合格目标。原先未改病例、只加编辑声明的 10 个变体也被识别，旧目标恢复数因此从 16,981 修正为 16,972。补分类、恢复与调整台账

v4 最终为全部 55,991 归档单元建立去向，保存 109,599 条已审判断，其中 77,781 个合格判断落在 38,123 单元、11 来源。具体适配包括按完整原题精确恢复 DiversityMedQA 选项和答案、区分文本“视图”与必需图像、恢复 MedRGB/MedCF 中间导出漏带的旧理由与原件字段。修复后的逐字段检查通过，不能把中间缺漏写成从未发生。LabTest 与 EquityMedQA 的评分接口、MedCF 的知识编辑步骤、MedMKEB 的图像仍未满足本轮合同，所以这四个取得来源没有进入正式比较。

R5 完整合格池有 35,872 单元，明显大于其他类别。曾预览删除七个完整来源、以及 3,000/3,500/4,000 比例预算；这些方案未实施。最终用户确认保留完整 v4，另建 v5：所有合格 R1–R4 目标保留，八个 R5 来源各不放回抽 450 单元，共 3,600。该设计控制来源覆盖和成本，不是最优功效设计，也不保证疾病或人口属性均衡。

抽样先固定一次随机种子，逐来源对唯一 ID 排序，再执行 `random.Random(seed+":"+source).sample(ids,450)`；不按旧预测、难度或新方法成绩选择，也不因结果不利重抽。不同来源入选率约为 3.57%–64.01%，450 个单元对应的原题根数也不同，不能称每来源 450 个独立患者。原 `labels` 保留，新增 `evaluation_labels` 决定本轮归类；未抽中 R5 的 R1/R5 单元仍可以只作为 R1 计分。冻结抽样协议、实际算法及字段含义

3.5 最终 11 来源组成与所有分母

下表是 v5 原件统计。“判断”指选中的目标注释，“R”列指具有该评测标签的比较单元。一个单元可以有多个判断和多个标签，所以不能把这两种数量相加。原始来源统计 CSV

来源	单元	判断	R1	R2	R3	R4	R5
M01 MedEinst	1,780	2,816	1,780	0	680	0	0
M02 MedPIC-Bench	167	182	96	75	10	0	0
M06 HIV 治疗因果情景研究	13	13	0	0	0	13	0

来源	单元	判断	R1	R2	R3	R4	R5
M10 CPV-MedQA	451	451	1	0	0	0	450
M11 Counterfactual Cultural Cues	517	517	67	0	0	0	450
M12 FairMedQA/ AMQA	584	584	134	0	43	0	450
M14 Diversi-tyMedQA	454	454	0	4	0	0	450
M17 MedPerturb	450	1,344	0	0	0	0	450
M20 MedCoun-terFact	788	1,720	788	0	0	0	450
M22 MedRGB	450	4,469	0	0	0	0	450
M23 BioRAB	450	450	0	0	0	0	450
并集/各类边际	6,104	13,000	2,866	79	733	13	3,600

类别成员合计 7,291，而并集是 6,104：R3 的 733 单元全与 R1 重叠，R1/R5 重叠 450，R1/R2 重叠 4，R2/R3 重叠 3。R4 只有 13，R2 只有 79，覆盖稀疏本身是数据结论。13,000 判断也不是 13,000 次独立提问；同一题可承载多目标，同一参照可被多个单元共享。

物化后每系统有 13,905 个唯一输入，包括参考端；离线有 15,616 条原生评分映射，其中参考 6,818、非参考 8,798；另有 34,753 条判断—输入溯源链接。归档数、合格数、选择数、输入数、评分映射数与链接数服务于不同步骤，任何一个都不能随意称为“病例总数”。物化检查、冻结接口与 34,753 链接说明

3.6 系统实际看见什么，分数怎样产生

模型只读问题、原生选项、完整给定证据、答案格式及明确预算；题号用于记录，gold、R 标签、标注理由、配对另一端答案和评分映射不进提示。原题与变体独立初始化。MedEinst 保留开放诊断；MedPIC 是原生多选；MedPerturb 按就诊/管理/资源目标展开；MedCounterFact 保留假设证据；BioRAB 保留当前前提、假说和示例；MedRGB 保留六档固定材料，100 档为参考。

本地 MedRGB 的六档材料可再追加外部检索，因此不能宣称完整照搬其官方静态证据评测。必需的扰动材料也不能被干净检索替换。各基线的语料、检索机制、骨干和预算并不完全相同：统一的是本轮原题与评分边界，不能由此宣称控制了全部资源因素。历史预测仅在题目、选项顺序、固定证据、输出预算及方法配置精确一致时复用；按题号相同复用不足够。输入权限和精确复用

评分先在每个单元内平均非参考原生任务的正确性，再对单元等权平均。ALL 的分母是 6,104 单元，不是五类百分比的平均，也不是对 13,905 输入平铺求平均。选择题匹配选项，多选保留集合 exact/F1，关系标签归一匹配，开放诊断采用既有 canonical 映射；不是重新请医学裁判判断整段回答。无效输出、投票平局和算法失败保留在完整分母计错。R5 的变体准确率、两端同时正确率与答案一致率分开：稳定地给出同一个错误答案不是成功。评分与失败处理

3.7 已证明的价值、质量边界及作者可追溯的证据

数据贡献是把已有来源整理为判断中心的五类体系，并实现了可检查的分类、资格、抽样、原生输入和评分链条；不是新写 55,991 道临床题。七系统配置的完整结果显示，R1 最佳仍仅 31.44%，

R3 最佳 30.42%，ALL 为 47.35%–51.61%，R5 为 63.42%–73.37%。这支持研究“整体准确率掩盖了哪些任务弱点”，也是后续五 head 与五 agent 集成的起点。但这里测的是所属子集上的原生任务表现，来源、任务和类别有关联，不能仅凭低分断言模型内部一定没有执行某种思维操作。完整七配置与 42 项指标核验

来源真实不等于答案可靠。MedEinst 中新增相容支持不保证唯一疾病成立；MedCounterFact 存在点估计、显著性与具体结局绑定的边界。R4 的 13 题是作者生成场景参考的一致率：后续取得的原表表明六位专家确实给整个题目、答案和解释做过质量评分，但没有独立选出的专家 yes/no 金标。因此既不能写“完全无人检查”，也不能将其当真实患者的确定反事实结局。HIV 参考资格补证

完整 v5 已用于模型评测和 head 开发，不能把优化后的同批成绩改称未见测试。v5 中 2,116 单元属于旧 v3、3,988 不属于；后者不保证更早未生成或未审阅。同一来源的来源组、研究编号、前提、患者和独立临床试验也不是同一个概念。后续资格审核及确认集的暴露须逐阶段记账，不能用文件名 test 或“没有读分数”代替隔离证明。

发布边界同样属于复现事实。冻结来源台账中八个取得来源有明确许可声明，七个未找到明确数据许可；“未声明”既不是作者明示禁止，也不是可套用本项目许可。历史公开包发布注释、审计、必要引文和官方版本定位，没有镜像所有原始题库，因此不能称可脱离原始来源一键复现。原题根、清洁文档、MedPIC 普通参照、必要图像与原生编辑步骤必须分别还原。此处复述历史核查，不新增法律判断或宣称已重新核验当前网站。来源许可、发布范围和依赖

作者复核数据链时可按下列证据顺序进入；这些是实际文件，不是待执行计划：

- 采集与出处：26 来源的官方地址、固定版本、取得状态和原生依赖；配合来源主记录辨别后续更新。
- 审核修正：172 判断的修改、前后计数与评分资格；同目录三份 JSONL 保存逐项 before/after。
- 完整覆盖：归档去向和完成检查；exports/archive_unit_coverage.csv 与 all_reviewed_target_annotations.jsonl.gz 分别保存单元和目标层。
- 最终选择与重放：配合 sampling_protocol.json、r5_sampling_frame.csv、selected_r5_unit_ids.json 和 replay_sampling.py 复现选择；selected_targets.jsonl.gz 保存 13,000 判断。
- 实际输入与评分映射（本地原件定位：`/home/data3/txy/Documents/Codex/2026-09-11/agent-md-medrgag-workspace-guide-md/results_v5_m0_m2_m4_m5/items.jsonl`；见大型依赖说明）：与同目录 evaluation.jsonl、preparation_validation.json、validation.json 联结；预测与分数按具体方法运行目录追溯。
- 本轮只读核验：保存 33 个原件哈希、完整来源/类别统计、标签重叠、抽样重放及全部 42 个基线指标；原文件语义保持检查通过，无新模型或评分。

因此可以陈述我们提出并操作化五类功能体系、构建跨来源评测并揭示多系统的薄弱表现；目前不能声称五类穷尽医学因果推理、完成独立临床专家全库验收、证明全体来源相互独立，或已核定“全球首个”同类体系。阶段性失败与质量修正是构建方法的一部分，保留它们才能解释最终 benchmark 的含义。

四、七系统与五类 head：实现、研究转向和实验证据

本篇是供共同作者理解研究全过程的证据底稿，覆盖正式七配置的形成、R1–R5 head 的研发及其向 CF-MoA 提供的组件。这里的“采用”按具体时期和范围解释：某个专项 head 已交付，不等于它已在七系统全部 v5 类别上运行；后来组成 CF-MoA 的版本也不能倒写为早期专项版本。现有数

据已支持七配置基线和七系统 R1–R3 的共同提升，同时保留对机制归因有决定作用的控制。所有数字来自已保存结果，本次只读与重组，没有新增推理、评分或训练。完整逐行来源、哈希与核验方式见七系统审计、head 审计。

4.1 七个系统到底是谁，为什么存在多个“修复版”

正式比较是六个方法家族、七个配置，使用 Llama-3.1-8B-Instruct 和 Qwen3-8B 两种原骨干。它覆盖直接回答、检索增强、检索与生成结合、多轮候选协商、纯生成背景和状态控制检索等不同流程。七条曲线是七个完整系统的实测结果，资源和适配不同，不能解释成七个算法在完全相同计算预算下的净效应。

标识与当前身份	骨干	实际流程和主要预算	原生接口与选用版本
M0 Direct	Llama	无追加检索；保留题目自带的必要证据；最终 greedy，普通回答上限 64 token、鲁棒性输出 2048；上下文 98,304	当前题目独立回答，不向模型展示其配对另一端
M2 MedRGAG all-Llama	Llama	Textbooks + Wikipedia，BM25 每源 32→MedCPT 初排 5→5 份 KGCC 摘要 →1 次探索 →5 份知识生成 →1 次 KADS 选择 → 重排 →reader；每个新增完整输入 13 个 LLM 阶段	all-Llama 指生成阶段，MedCPT 仍是独立检索模型；reader 普通 64/鲁棒性 2048，98,304 上下文
M3 MA-RAG intrinsic	Qwen	每轮 8 个 solver 候选，至多 4 轮；一致可早停；分歧时 1–4 查询；PubMed + Textbooks + Wikipedia，BM25 共 32、MedCPT 每查询 2；solver 温度 0.7/2048，query 温度 0/8192	solver 非 thinking、query 使用 thinking；按 token 熵组织候选历史；唯一最高票胜出，平票无效；完整 131,072 上下文
M4 MedRAG-Llama	Llama	单轮完整 MedCorp 四语料，BM25 每源 32→MedCPT top8；追加资料最多 30,000 token；温度 0.7、输出 2048、上下文 131,072	选用全量结构化修复版：明确任务合同并使用逐题 schema 约束解码
M5 MedRAG-Qwen	Qwen	检索和预算与 M4 对应；Qwen 关闭 thinking	保留原输出协议，未同步使用 M4 的结构化修复，故 M4/M5 不是纯骨干消融
M6 MedGENIE v2	Llama	零外部检索；有选项时 3 份选项相关 + 2 份无选项背景，无选项时 5 份无选项背景；生成温度 0.9、frequency penalty 1.95、每份 512；greedy reader 最多 2048	官方示例改成 Llama 聊天轮次；五背景全部交给 reader；多选合法单键可确定性包装为单元素数组；131,072 上下文
M7 TC-RAG typed-control-v2	Qwen	检索使用完整 MedCorp，BM25 每源 32/CPT top8；最多 8 步、每步 2048；零基步号至少 4 且全词表熵和小于 1.2 才接受答案	非 thinking；动作恢复、拒绝反馈、预算提醒、题型反馈与确定性表示转换组合；FP32 熵计算，131,072 上下文

M1 是早期 MedRGAG 初始检索对照，只做 BM25/MedCPT 加 reader，没有完整 KGCC、探索、生成和 KADS，不能当成独立 MedRAG，也没有进入完整 v5 七配置表。历史 M6 则是 i-MedRAG，多轮追问增加了实际成本；v5 暂停时仅 52/13,905 终态，其中 40 新生成、12 复用，41 原生有效、11 无效。后续 128 题性能试验也没有补成全量。用户要求寻找替代后，选中了有官方实现、无需新训练的 MedGENIE ICL 路线，旧 i-MedRAG 目录和结果保留原名。因此既不能把旧 M6 和新 M6 重复计数，也不能拿 M1 凑七。见直接回答/初始检索、i-MedRAG 暂停、MedGENIE 替代依据。

基线形成过程中，任务适配确实改变了系统。M4 原版全量 ALL 为 29.76%；100 个固定开发输入上，原协议、明确提示、再加 schema 的原生正确数为 36、42、49。随后保留实际检索消息、重新生成全部 13,905 个最终答案，ALL 达到 48.20%。这是已知接口缺口的修复，不能再用 29.76% 作为唯一比较对象；约束解码改变允许生成的 token，也不能称纯后处理。M5 没有同步修复，使两配置仍含协议差异。M4 修复全过程、全量采用。

MedGENIE 首版虽然 24/24 输出合法 JSON，却将两段 completion 示例塞进单个聊天消息，真实病例下出现重答示例题。改成示例 user/assistant 轮次、真实问题作为最后 user 后，含示例主题词的背景从 66/120 降至 1/120；这只是定位修复的辅助指标，不是背景医学正确率。多选字符串包装保留原值，不推断缺失选项，后来的多选漏选不能靠“格式有效”消除。其 5 份背景、采样参数和官方示例保留，但骨干、聊天模板、开放式任务及 reader 输出预算是本地适配，不称复现原论文表格分数。适配与失败。

TC-RAG 旧版解析失败立即结束，遗漏了论文说明的异常恢复；仅恢复在同 100 输入上使协议有效 61→77，原生正确 33→51/105 评分映射。完整 typed 组合达到 99/100 和 70/105，但还包含额外反馈、预算提醒及类型转换，不能把全部增量归给异常恢复。新的 384 输入验证完整组合协议有效 366/384，随后才全量运行当前版。M3 的 CPU 熵向量化、PubMed 偏移读取，M2 的阶段缓存和各方法断点恢复属于执行工程，不另算推理贡献；M3 全量仍保留 188 无效答案、135 平票、18 运行无效等终态。TC-RAG 消融与采用、MA-RAG 主记录、MedRGAG 主记录。

七配置各覆盖相同 13,905 唯一输入、15,616 评分映射，对 6,104 个选中单元汇总。下表是单元内任务正确率再对单元等权的百分比，ALL/R5 不能简单换成一个整数正确题数；R1–R4 在当前选中范围每单位一条非 reference 任务，可以对应后文整数。R 标签多重归属，ALL 去重而非五类均值。

配置	ALL（6,104）	R1（2,866）	R2（79）	R3（733）	R4（13）	R5（3,600）
M0 Direct	48.10	30.04	8.86	17.87	38.46	65.70
M2 MedRGAG	48.81	31.33	7.59	24.69	53.85	65.88
M3 MA-RAG	51.61	26.73	34.18	8.59	38.46	73.37
M4 MedRAG	48.20	27.84	29.11	30.42	53.85	65.28
M5 MedRAG	47.35	28.58	41.77	25.24	53.85	63.42
M6 Med-GENIE	48.02	29.94	18.99	21.42	61.54	65.15
M7 TC-RAG	49.43	31.44	29.11	28.92	30.77	66.17

4.2 为什么从基线比较转向 head，而没有直接继续堆检索

早期分类筛查发现 R3、R2、R1 较弱，但错误性质不同：R1/R3 有大量诊断未映射，R2 主要是输出合法但集合错误。抽查同时看到了括号缩写导致的匹配损失、真正不同疾病、粒度差异及多诊断列表，不能把所有未映射补成正确。R2 则有更直接的过程反例：患者 CrCl 为 70，模型却把它代入 15–30 区间；另一个输出将检索文献中他人的生活习惯、突变归到当前患者；撤掉晕厥支持后，又漏掉跌倒史仍支持的其他药物。这些观察促使研究从“资料是否更多”转向“事实属于谁、规则是否适用、哪个选项的哪条支持仍成立”。诊断与文献取舍、原始病例证据。

七系统之间还混合骨干差异。为拆开这一点，实际进行了 167 道 MedPIC× 两骨干 × 有无同一份检索证据 × 三种子，共 2,004 次新生成，统一回答提示、schema、温度与输出预算。75 道 R2 上三种子平均准确率分别为：Llama 无检索 19.56%、有检索 21.78%；Qwen 无检索 42.22%、有检索 52.44%。Qwen 检索收益主要出现在 66 道 None 题，9 道仍应选药物题反而从 22.22% 降到 7.41%。Llama 检索收益跨种子不一致。该实验定位了骨干/适配条件及检索作用，却没有运行七条完整上游流程，也不是新 head 的 52.44% 正式成绩。M0/M2 这 167 题的输出均未到 64-token 上限，短预算也不是已证实的差距原因。受控设计及完整结果。

由此形成的共同原则是：先保持原骨干和真实上下文，定位最小失败环节；区分事实抽取、支持执行、候选决策和最终序列化；用同范围普通重答、同资源目录或同事实执行解释增量；同时看修复与误伤。它不要求每个 head 都成为独立训练模型，也不把分类 R 标签交给模型作 oracle 路由。

4.3 R1：新增支持的目标，以及实际交付的组合封装

R1 要回答的是：新增相关信息后，系统能否利用这份支持完成当前判断。最初没有凭名称再造一个“R1 推理模型”，而是先检查已研发 R2/R3 组件能否迁移，再补缺口。实际候选按可见任务结构分派：诊断用公开目录重决策，用药规则题用支持执行，其余保持原输出。全部 2,866 单位中，1,780 进入诊断目录、72 进入规则、1,014 透传；其中新增诊断范围 1,100 题，新增规则 62 题。因此 R1 的有效实现是复用成熟组件的 wrapper，有完整独立调用接口，而非第三套独立知识算法。调查、扩展与交付。

补缺口也实际尝试过。单选短提示、移除旧答后的普通重答在完整 202 题扩展中没有共同净收益，未进入主头；关系任务尝试当前命题范围、移除旧答案、保留/删除检索等组合。最终 201 问句族、91 个 review 的同期匹配对照中，M4 普通重答 102→ 目标提示 118，M5 为 120→122；相应聚类 95% 区间为 [1.03,14.93] 及 [−5.19,7.37] 个百分点。它支持 M4 的局部信号，尚不支持跨骨干共同增量，未据最有利旧批次择优混入主 wrapper。R1 内与 R5 重合 450 单元全部透传，这项设计事实不能宣传成 head 在 450 例上新学会了不变性。202/201 扩展与取舍、同期关系控制。

R1 七系统全部净提升。M4 修复 481、误伤 54；M5 修复 584、误伤 36。去掉其包含的全部 733 个 R3 单位后，余下 2,133 单位在七系统仍净增 261–319 正确，所以收益不只来自重报 R3。另一方面，R1/R2/R3 共 3,678 个类别成员实际仅 2,941 个不同单元；R3 完全包含于 R1，R1∩R2 为 4，R2∩R3 为 3。下面 21 组是真实专项结果，不是 21 套互不相交测试。

原系统	R1：原正确 →head 正确 /2,866	R2：原正确 →head 正确 /79	R3：原正确 →head 正确 /733
M0	861→1329	7→29	131→338
M2	898→1323	6→23	181→340
M3	766→1260	27→43	63→238
M4	798→1225	23→39	223→386
M5	819→1367	33→46	185→443

原系统	R1：原正确 →head 正确 /2,866	R2：原正确 →head 正确 /79	R3：原正确 →head 正确 /733
M6	858→1317	15→38	157→305
M7	901→1331	23→37	212→349

“优化前”已与正式选用 v5 逐行比对：R1 的 20,062 条、R2 的 553 条、R3 的 5,131 条方法 × 评分记录均零差异。表中 21 组全部为正，R1 增益 14.83–19.12、R2 为 16.46–29.11、R3 为 18.69–35.20 个百分点。这是跨原系统的开发结果，可作为主要成果；复用及暴露边界见后文，不能将它们改称七系统的完整 CF-MoA 全类别成绩。

4.4 R2：从长审计失败，走到有作用域的三值支持执行

R2 要求撤销失效支持，同时保留仍成立的其他支持。第一轮在修复后的 M4 上追加通用、来源、支持复核，79 题正确从 23 变为 12、12、22；支持版虽修复 6 题，也误伤 7 题。继续把完整支持图交给模型并输出长审计，程序版仅 2/79 且 34 无效；缩成局部撤回虽减少无效，却不能补回漏选，181/241 前提仍 UNKNOWN。原子判断 632 调用全部合法、无截断，两个候选分别仅 7/79、8/79 正确，证明问题不只是 JSON。后续解释到动作映射、CAD、自然词标签、整页指南检索、更长 thinking 等都实际试过，未解决语义绑定和保留侧。失败索引。

有效版本把职责拆开。模型只从当前题文提取正向患者事实和句 ID；有限 71 条规则库给出选项、条件和适用问句范围。程序把每个支持条件记作 MET、CONTRADICTED 或 UNKNOWN，执行数值比较、否定和独立路径合并。某条风险撤销，只删除该路径；另一条仍 MET 时保留选项；若没有确定依据但原答案选过且仍 UNKNOWN，沿用原判断，不把“未提及”强行当“不存在”。例如“无晕厥史”不能撤掉跌倒史仍成立的支持。问句只问肾功能时，程序不能用所有其他禁忌替它作答。None 与实质选项互斥，覆盖外 24 题直接保留原方法；当前有限规则覆盖 55/79。完整执行顺序。

这里的成功包含具体版本修复。早先“串联只能恢复 1/9 保留题”的负结论受 tuple/list 组装错误影响；修好后复用原生成离线重算，普通新答 + 默认程序为 49/79、保留 5/9，条件新答 + 默认程序 55/79、保留 3/9。应保留故障而撤回受影响结论。正向字段版本修复了否定式字段的极性混淆，但句 ID 存在仍不保证语义蕴含，事实证据被拒绝后回到 UNKNOWN 也可能继承错选。覆盖外重新回答在 Qwen 有收益，在 Llama 的 24 题却有 13 条截断，因此没有选作共同默认。当前交付及版本取舍。

总分必须和标签分布一起读。75 道 MedPIC R2 里 66 题答案为 None、仅 9 题仍有药物；在 head 覆盖 55 题中 46 题为 None。保持同覆盖，其余 24 题沿用原答，仅把 55 题全改 None，七系统总分都高于真实 head，但九个保留题必为零。真实 head 在五个系统改善保留侧，M2 保持 4/9，M7 从 3/9 降至 2/9。以下同时展示整体和保留，防止高分的常数策略掩盖研究目标，也防止机制叙述藏掉强控制。

系统	原正确/79	head 正确/79	同覆盖恒 None 正确/79	仍有支持：原 →head /9
M0	7	29	48	5→6
M2	6	23	47	4→4
M3	27	43	58	1→3
M4	23	39	58	3→4
M5	33	46	56	0→6
M6	15	38	52	2→5

系统	原正确/79	head 正确/79	同覆盖恒 None 正确/79	仍有支持：原 →head /9
M7	23	37	54	3→2

程序执行也并非普遍胜过模型：旧版同 facts、给足推理空间时，Qwen 模型 43/79、程序 44/79，Llama 模型 35、程序 34。可支持的是确定执行与免除额外执行生成，以及某些受控新规则上的增量，不能写 “LLM 无法执行规则”。七方法真实 head 的 130 次 R2 修复均从原生有效答案出发，故整体提升也不能降格为只修 JSON。当前结论是支持管理流程有实现和开发证据，有限规则覆盖、未知事实继承和不平衡来源仍限制泛化与总分归因。同口径审计。

4.5 R3：为什么保留目录重决策，而没有采用更复杂的证据链

R3 要求在新证据下重比候选。首轮做证据审计、临床查询、患者事实绑定、追加检索和候选覆盖；更精细的查询并未稳定胜过普通重答。随后训练病例记忆得到开发 124/128、扩展 535/552 的高分，但主要依赖公开训练标签的近邻检索，不能作为原模型证据更新能力的主要证明，因而撤出核心方法；代码和高分都留作历史。该取舍不否认外部记忆本身可以是合法方法，而是它改变了本项目要回答的问题。两轮负结果与记忆路线、定位修正。

保留的目录头更直接：提供固定公开 49 诊断目录，将候选绑定为可评分代码，在六个固定排列下用原骨干读取当前患者及原系统实际上下文；从患者分数中减去固定无内容先验，再投票回译为诊断。它把开放生成变成明确候选决策，既能消除一部分名称/列表不兼容，也可能真正改变诊断选择。目录 49 项和项目评分器原冻结 46 项映射是不同资源，未根据新答案追加别名或改 gold。全 R3 的 733 题由 680 诊断、10 规则、43 透传构成；10 道规则题调用冻结 R2 接口，3 道与 R2 开发重合，另外 7 道在七系统均 7/7，仍为已暴露同来源迁移。公开目录形成、规则迁移。

六排列和校正不能只用最终分数证明。完整 680 诊断题的控制如下；平均正确率从原始 20.97% 到单次目录 45.44%、未校正票 46.47%、校正票 46.13%。主要稳定增益来自明确目录后的重新决策，投票和校正的贡献依系统而异。M5 校正比未校正多 8 题，M2/M6/M7 分别少 10/12/6 题。它们不推翻七系统加头后的净收益，却排除了 “校正是所有系统共同增益来源” 的说法。

系统	原正确/680	单次目录/680	六排列未校正/680	六排列校正/680
M0	116	299	314	314
M2	163	320	325	315
M3	33	215	200	204
M4	203	339	359	359
M5	160	382	402	410
M6	137	296	288	276
M7	186	312	324	318

早期 40 题名称控制应按实际配置拆开。它先发现纯模型名称规范会误改原本正确的病名，后加公开目录精确匹配优先；可靠名称规范因此为下表 15/11，而旧纯模型版本均 11/40。初始名称规范和名称直接回答上限 128 token，后续代码与简短推理三臂上限 384，均温度 0。探索表说明候选决策可以超出名称包装，但不能把不同表示/额度拼成一个统一的等预算消融。

同 40 题早期目录臂	M4 正确/40	M5 正确/40	新增回答额度/可见信息
原答案	12	9	既有原系统输出

同 40 题早期目录臂	M4 正确/40	M5 正确/40	新增回答额度/可见信息
可靠名称规范	15	11	128 token；仅原答案字段 + 公开目录，先精确匹配再模型规范
名称直接目录选择	15	18	128 token；患者和原实际上下文 + 目录，无旧答案
代码直接目录选择	18	21	384 token；同患者/上下文，公开目录映射到单 token 代码
名称 + 简短推理	18	19	384 token；要求简短推理
代码 + 简短推理	21	22	384 token；要求简短推理

原记录后期曾用 18/18 概括患者条件目录候选；这并非两个骨干同一“名称直接”臂的结果，作者应引用上表的明确配置。Llama 两个推理臂分别 4/3 次达到长度上限，按预设回退原答案后计入全分母；Qwen 无截断。另一方面，七系统 R3 合计 1,272 次修复中，1,186 来自未映射、23 来自其他原生无效、63 来自有效但错误；这些未映射包含错病、粒度和多诊断，不等于“95% 医学上本来答对”。两类解释都不能省略。40 题逐版控制、完整七方法比较。

更复杂机制也得到真实负结果：双向候选比较、逐候选核验、原句选择、候选均分医学资料、资料效用筛选、反向病例似然、先生成鉴别条件、逐观察关系、名称绑定、训练统计特征与 NLI 分支先后试过。部分在局部例子改善，但未在两个骨干共同胜过保留目录头。例如 40 题反向病例似然为 1/11，同资源直接评分 20/18，原校正 21/24；知识池候选均分 7/16，原资料列表 18/20；逐候选诊断核验 19/20，仍低于 21/24。关系判断还把没有患者事实的标题判成支持，交换任意代码会改变固定观察表。因而没有把“更长、更结构化、更有解释”当作采用理由。完整探索导航及各阶段制品、方法成立范围审查。

4.6 冻结后验证、来源暴露与七系统复用合同

七系统迁移不是重新跑七条上游检索链。诊断终端使用各方法原骨干和归档实际上下文，新增必要的候选评分；同请求先验及已有分数可缓存复用。规则事实提取只看当前可见题文、选项及必要字段，不看方法旧答案或其检索历史，因此实际只需要两骨干的新事实，再与七份不同原答案离线合并。R1 只是上述组件分派；其接口回放证明实际请求与保存结果一致，不是又生成一批质量证据。相关调用、score file、hash 和 original 逐行一致性在head 机器审计中逐配置绑定。

外部和机制验证确实做过，不能概括成“从未独立验证”；但每组的独立性不同，不能一概称未见临床测试。

范围	实际结果，Llama / Qwen	暴露、分母及可回答的问题
ASCENT 47 病例、14 目标病种	自由生成 4/47、20/47；单次目录 38/47、39/47；未校正 39/47、39/47；冻结校正 38/47、39/47	42 来自源 train、5 来自源 test；首次按冻结头、旧先验作新来源验证，之后同批参与定向开发。只报本项目 canonical 分数，不是官方语义 F1；六票/校正整体未胜单次目录
CUPCase 冻结三批 4 + 8 + 6 = 18 记录	校正 15/18、16/18；未校正 16/18、17/18；单次原生四候选 15/18、18/18；字符归一 15/18、14/18	不含此前 2 条适配开发例；各批资格先固定、流程不按前批成绩改；完整病例四选一，不是 CF 配对，也未跑七上游系统

范围	实际结果，Llama / Qwen	暴露、分母及可回答的问题
冻结规则 11 构造组 ×3 端 = 33 输入	普通初答 7/33、6/33；同 facts 模型执行 6/33、17/33；程序 21/33、25/33；三端全对程序 5/11、6/11	每组基础/新增支持/无关信息；新机制探针而非 33 临床患者；基础到无关端保持仅 7/11、8/11，Qwen 有 2 组正确 → 错误
同 facts 问句范围 48 探针	去范围 24/48→ 保留范围 48/48，两骨干同向	3 机制 ×2 问句范围 ×8 实现，24None/24 保留，非 48 独立患者；正向字段版修复之前已见反例，不把版本修复再包装成独立测试

ASCENT 23 例既往已命名目标，另 24 例未命名；后一组校正仅 15/24、16/24。原生 test5 上各目录臂均 4/5，不能把全部 47 称源 test。CUPCase 两条早期开发例还出现候选末尾标点捷径，统一格式后 Qwen 表面增量消失，这才促成后续冻结比较。33 端规则探针则发现 eGFR/CrCl 错读和 “未分类射血分数” 被当 false；句 ID 校验未消除事实语义错误。上述成绩既保留有限迁移的积极证据，也解释了为什么没有据此结束所有研究。ASCENT 及规则验证、CUPCase 三批与捷径控制、48 范围探针。

4.7 R4：从临床机制缺失，转为给定模型下的局部干预执行

R4 要求从改变的前提推出未直接给出的后果。v5 只有 13 条 HIV ART 假设场景，参考 8 yes、5 no，七基线正确 5/7/5/7/7/8/4。后来补获六专家对题目、答案及解释的整体质量评分，但没有新增独立二元临床金标；仍是作者预期答案一致率，常数 yes 即 8/13。初轮干预—机制—后果短提示、反问极性和形式程序编译都实际运行，发现患者事实与检索病例混绑、解释与答案极性冲突，以及在资料不足时擅自闭合机制。已知药理也不能识别某假设个体的确定反事实结局，因此没有把这些临床尝试定为有效 R4 头。起点、原参考与首轮尝试。

随后用布尔结构、CLadder 及生物网络逐步分开 “机制是否已给” “语言是否忠实编译” “程序是否正确执行”。形式成功不能自动迁到临床，最终有效路线明确要求输入已经给定可信生理模型、13 维状态、参数、辅助量、未来餐食和原给药计划。原骨干只生成一个有类型的局部修改：调整某区间 basal、删除 bolus、移动 bolus 或改剂量；程序复制所有未变事件，用同一作者 ODE 从同一起点算事实/反事实轨迹，再按题文时点、阈值读出血糖和 yes/no。直观上，要求模型 “改这一处”，比让它重写整份给药计划少引入无关改变。当前接口和数学定义。

冻结后 24 个新虚拟 profile，每个四动作 × 三个时点，构成每骨干 288 问。下表同工具 full 也使用同一模型及读出，比较的是全计划重述与局部修改；no-do 保持其他条件、移除干预，检验是否真正使用改变。

骨干/臂	二元正确/288	联合数值正确/288	完整动作 + 问句忠实/288
Llama 普通重答	118	0	不适用
Llama 同工具 full	286	270	263
Llama 局部 patch	288	288	288
Llama patch 去 do	234	67	不作为动作忠实比较
Qwen 普通重答	187	0	不适用
Qwen 同工具 full	265	222	213
Qwen 局部 patch	288	288	288
Qwen patch 去 do	234	67	不作为动作忠实比较

patch 相对 full 联合数值多 18/66 题、零误伤，两骨干完整输出也 288/288；它是真实且强的受

限机制成果。独立单位为 24 个 profile，不是 288 患者；只验证同一模型、四动作、有限问句、新参数/初态，未验证真实临床模型识别。标准 ODE 求解器不是本项目发明，也不能将此 288 补进原 v5 的 13 题，或宣称七系统 R4 已经共同改善。后期 CF-MoA 的 A4 只在提供模型的条件面板激活，临床 v5 不能凭 R4 标签强行启用。冻结验证全表及限制。

4.8 R5：已交付 F 的收益，与后续学习方案为何没有替换它

R5 目标是无关变化后保持正确判断，同时在相关变化时仍会响应。首轮完整输入短提示及文档纠错范围澄清共 1,440 调用，未得到双骨干采用证据；用户指出停止过早后继续研发。先尝试完整原生回答的五票共识，绝对三票即可提前停止。获胜者返回整段 raw，包括 errors 数组，不能只拼一个正确选项。NLI 又发现仅投影当前命题会带来天然一致、忽略前提，遂改成直接评分和一次新响应后的评分两路径，各自交换两种二元代码映射后按语义等权合并，再生成完整原生输出。最终 F 的 NLI 为四次分数回调 + 两次完整生成，其他题型 3–5 次生成；不删原始上下文，不读配对另一端。F 形成、接口与交付。

完整 F 确已运行公开 optimize 接口回放：每骨干 656 不同输入，共 1,312 输出、5,032 缓存回调，和真实先前请求逐次匹配；这是复现检查，不是 1,312 新病例。主 R5 为 208 单元 = 64 开发 + 128 扩展 + 16 冻结后新组，每骨干 608 评分映射。结果如下，整体百分比按单元等权，并非一个可直接取整的双正确计数。

范围/指标	Llama 对照 →F	Qwen 对照 →F
全 208：历史原答 →F，参考正确%	71.15→75.32	69.55→72.76
全 208：历史原答 →F，变体正确%	68.27→70.64	67.72→71.28
全 208：历史原答 →F，双正确%	60.19→65.90	59.17→66.47
全 208：有效一致%	75.10→82.66	72.63→84.01
全 608 评分映射正确数	450→466	411→448
旧 192：完整 Maj5→F，双正确%	64.62→65.14	63.68→65.24
全 208 中的新 16：匹配原生单答 →F，双正确组数	11/16→12/16	12/16→13/16
另 8 新相关变化强控制：匹配单答 →F，双正确组数	3/8→5/8	5/8→6/8

全 208 相对历史的修复/误伤为 55/39、69/32，其中格式无效修复 2/33，所以总收益包含投票、格式及 NLI 组合。相对同旧 192 完整 Maj5，新增分支仅多 0.5208/1.5625 个百分点；新 16 各多一组，是真实但有限的冻结后增量。Qwen 新 16 历史原答 11/16 与匹配单答 12/16 不同，不能偷换较低对照。MedRGB 文档错误检测在 24 单元/144 输入上，Llama exact 仍 1/144，Qwen 从 24/144 降 22/144；返回完整 errors 不等于纠错能力已改善。最终完整结果与组件对照。

F 之后继续探索了支持审查、原句抽取、冻结表示训练、JSON 读出、实体重呈现、作者 NLI 监督及残差读出，保留了真正负结果和工程失败。W 用任务条件下的语义表示学习，X 测试代码映射差分，Y 只在作者验证集定半径/长度门再选择 W 或原 LM。W 在已暴露 J 的 40 个 R5 对上，两骨干双正确分别 31/40、36/40，优于 F 的 26/40、33/40；但固定假设、改变前提的 T 控制 32 对只 1/32、1/32，原 LM 均 27/32，说明保持表面一致可伴随丢失应变能力。X 差分也未通过，标量控制不能双骨干共同胜出，均未采用。W/X 完整结果。

Y 的 M4 半径门在 T 接受 24 端，W 仅正确 5、同范围原 LM 正确 21，额外 16 误伤、零修复；Qwen 全部回原 LM 所得恢复属于原模型。长度门同样把所有 T 交回原 LM，距离没有显示额外选择价值，因此整个门族停止，不追调分位或为两骨干拼不同策略。最后 CAD 资格完成 583 家族/2,915 端审核，保留 train246/dev134；所谓“五头”监督控制只有 plan，未写完新训练器、提特征或拟合。这套五训练头计划不是 R1–R5 五功能 head。新的 D 确认 128 母题 + 8 强控制有输入/检索准备和人工资格审核，却仍零模型表示、零答案生成；不得称已验证新学习方法。Y 停止、CAD 计划与归档。

当前可复用的是 F 代码、完整输出合同及限定范围的配对收益，不是已经解决所有 R5 语义不变性的学习算法。其五票、映射平均、直接/响应后组合有已有方法基础，应据实引用。研究生成/取分共 12,151 次与表示试验 73,937 完成序列、54,057 前向批是不同成本单位；不能相加成一个“总调用”。平台两次 400 中断、主动停止坏读出和 schema 初始化失败均在原记录，不改写为没有做过，也不能当医学机制负结果。

4.9 这些 head 如何给后来的 CF-MoA 提供方法基础

五个 head 提供五种功能角色，但并非五套相互独立训练参数。R1 曾是组合 wrapper，后期 A1/A2 共享规则支持核，通过增加/撤销操作区分角色；A3 来自目录候选重决策，A4 来自给定生理模型的局部 patch，A5 使用 F 决策组件。最初 Router + Five Agents 设想包含有实质作用的聚合，后来多专家生成聚合及新增专家也真实运行过。采用的保守 B 主要依据可见能力选择单分支并确定性执行，不能画成五人每题同时会诊，也不能宣称所有协作承诺已验证。

这一历史解释了后期为什么集中在两个 MedRAG 配置做深度系统实验：它是在七系统基线和 21 组专项提升之后，选择两骨干实施统一路由、消融、强控制及全量 v5，不是整个研究只做了两个方法。B 相对两原系统完整 ALL 增加 10.09/12.01 个百分点，属于另一套真实系统结果；其 R1/R2/R3 分别为 M4 的 1,279/38/390、M5 的 1,336/46/440，与前述专项 wrapper 数值不同，必须保留版本身份。CF-MoA 完整各臂、保持/应变以及未采用扩展由系统篇展开。本篇依据为五角色、源码版本及实际调用图审计，各 head 原始分数不因此被替换。

五、CF-MoA：五种操作、失败协作与完整系统验证

本篇面向共同作者，解释已做实验的动机、实际方法、结果、改变方向的理由和可引用证据。它是 2026-10-03 的研究材料快照，不是待填数字的提纲，也不替代持续维护的实验主记录。阅读顺序按研究决策展开；每次运行中的 GPU 轮询不逐条搬入正文，但影响方法身份、预算、结果或恢复的失败会说明。全部数字来自已经完成的运行与冻结汇总，本次没有新增模型调用、评分、训练或模拟。

本篇的核心事实是：五操作并非最后为了给验证器命名而补的概念。R1–R5 已经分别指出新增支持、撤销支持、重新比较、推导后果和保持判断五种需求，已有 head 为其中一些受限需求提供了有效组件。09-21 希望将它们组织成操作专家，并通过真实互补和聚合超过强旧系统；这条生成式协作路线实际做过，而且多次失败。09-23 最终采用的 B 把有效组件组织成能力路由的五操作系统，其后完整 v5 显示两个骨干都有明确系统收益。候选验证 RCV 是后续增加的一条选择机制；它的跨骨干不一致既不能隐去，也不能代替整个 CF-MoA 项目的评价。

主要依据是持续主记录、2054 行全过程报告、09-21 原执行计划快照和09-28 完整收尾。原计划与当前同名计划经历过用户修订，不能只读现行文件倒推最初就决定采用 B。

5.1 原问题：五个 head 怎样成为五个 agent

先前 R1 入口已经把诊断、规则和其他格式分派到不同路径，因此它本身不是独立“新增支持算法”。R2 已有正向事实抽取、问句范围、三值规则重算及 UNKNOWN 继承；R3 已有公开目录内的原骨干重新决策；R4 已有完整给定生理模型下的局部干预执行；R5 交付的是 F，即任务适配后的多次采样和 NLI 双映射、双路径组合。把这些直接列为五个独立新算法会错失实际实现。09-21 计划因此先要求迁出旧 R1 分派，再真正开发独立 A1 支持覆盖核查，并为 A3 和 A5 设计额外的受控机制。

计划中的 agent 由操作职责定义，不以医学专科或权重文件定义。同一个 Llama 或 Qwen 可以承担多个角色，但每次实际调用仍有成本。统一的 InputPacket 包含当前合法题面、原选项、许可检索材料、原生 schema、必要的同题初答、可用工具和预算；AgentProposal 记录适用/部分适用/不支持、原生提议、claims、requested_changes、未决问题、检查类型和成本。患者事实、一般医学知识、假设编辑和真实工具结果应分开；可定位的引用只证明文本位置，不能自动等同医学蕴含。

最初设想首轮选择 1–2 位专家，有关键冲突时至多追加一次定向检查，再有证据约束地合并。这个目标比给五个提示起名字更具体：需要说明最终答案实际用了哪些不同操作的证据，并对同资源单 agent、同预算重答、相同专家 top-1 等控制取得增量。离线 R 标签、gold、分类理由、隐藏的另一端病例/答案、作者解释不能进入路由。静态端点往往没有显式“编辑前状态”，控制器应判断当前可见任务需要何种能力，而不是猜官方类别后查答案。

原计划也明确允许共享事实表示、规则执行和组装器，保留简单工具作为主要有效部件。原版要求独立 A1 有自己的支持覆盖产物，不能仅转发旧 A2/A3；当这条独立研发失败后，09-23 用户另行授权最简复用方案，才采用现在的 A1/A2 同核分解。二者是有记录的设计修订，不是第一次就完成五个独立专家协同。原计划 §0–4、§12 及 §15

5.2 建立可信起点：锁定采用版、迁移旧路由和区分验收层次

首先逐一锁定 R1/R2/R3/R4/F 的真实入口和依赖，排除同目录里的失败提取器、训练标签直返、早期布尔 R4 和未训练 CAD 计划。旧 R1 的新控制层回放七系统各 2866 输入，合 20062 条输入、75264 次缓存回调，返回值和请求逐项一致；这是迁移等价，不是 75264 次新推理或新泛化成绩。

A4 适配暴露了一个实质配置错误：公共默认 temperature=0 覆盖了采用版 0.7。团队暂停受影响路径，恢复完整采用 profile 及依赖哈希，再分别做请求一致性、同一响应的执行一致性和真实小批调用。Llama 又遇到 prepare 与实际输入相差 BOS，另一次跨异步/同步入口比较把 output_kind 变化误当模型参数漂移。修复观察边界后，两个骨干各 4 条真实请求与动作、求解器及原生输出验收完成；旧失败收据没有删除。由此形成后续共同原则：CPU 能构造请求、grammar 能编译、请求能进模型、完整语义输出可用、主任务得分提高，是五件不同的事。

运行器使用 SQLite 持久化请求意图、响应、实际参数和费用，完整请求及输入/profile 一致才可复用。提交后响应缺失保留 unknown，不能重抽到成功或当 0 成本；明确不可用与“有答案但错误”分开，完整成功率分母都保留。后期普通单题错误继续完成面板，系统性错模型、错输入、未知提交等仍需停止受影响运行。这个调整让方法能接受完整质量检查，同时保留真实失败。报告 §3、主记录阶段 A–C

5.3 独立 A1：从合同不可执行到完整运行但未采用

A1 最初尝试审计“哪些已知事实/合法知识尚未进入判断”，输出带出处的支持覆盖和补入建议。第一版不是低准确率，而是实际 grammar 兼容性失败：每骨干 111 条执行失败、10 条不适用，

共 222 条失败没有候选答案。遍历结束曾写 complete，因此随后补上首错锁和停止门，明确 complete 不能等于方法成功。

兼容修复后，M5 固定 d00003 又发生长度截断。诊断不是“答案差一个括号”：输出有重复引用、尚未完成覆盖和知识字段。A1-v2 改用有界证据 ID 及关系合同，r1/r2 排查 system 原生答案要求与后续审计要求冲突，r3 加强关系约束，r4 只检验有限结构空白，r5 再将重复表达压缩为状态码。各版本分开冻结，不把提示或语义改变都称工程修复，也没有无限增加输出预算。

r5 终于完成两骨干全 121 输入，373 次实际请求。M4 有 91 个可用提议、30 不可用，M5 为 60 可用、61 不可用；其中每边 10 不适用，其他主要是字段容量触界，M4 另 3 条关系无效。M4/M5 正确输入为 55/42，原生 74 单元均分 40.4505%/23.0631%，低于同知识规则单答 52.7027%/53.6036% 及旧 R1 分派 70.0000%/66.6667%。r5 没有碰 4096 总上限，却不能证明触界字段语义完整；因此保留不可用，不事后删未决字段换取分数。最终不采用独立 A1 r5，保留它作为后续实验池的一项明确未采用来源。

此阶段的正面交付是独立支持审计实现、严格输出/来源/成本合同及完整控制。质量结论则是这套更重的审计还没有超过简单有效组件。它不支持“所有支持补全都无效”，也不允许把修好运行器当 A1 方法成功。r5 终态与成本

5.4 新 A5 失败后为何保留 F；同工具与规则对照告诉了什么

新 A5 检验合格代码重映射视图和一次原文分歧复判，保留患者数值、否定、时间、问句与完整原生输出。两个骨干固定 smoke 均在第二题复判 2048-token 截断。M4 出现大段结构空白，M5 生成 1682 位引用 offset；限制结构空白和合法 offset 后，复判仍在原生解释/理由中重复并截断。两轮实际 14+2 次调用。用户明确保留负结果推进 F，所以新受控多视图 A5 停止，不将 F 改名成该候选的成功结果。

旧 F 单独调度后，121 输入每骨干 104 适用、17 不适用，725 次真实请求完成。其内部三次 JSON 截断票按原有有界投票政策处理，和整个运行失败不同。F 单独正确 76/70；固定能力组合按旧规则/目录、条件模型、F 和透传组织，成为强旧 B，正确 87/82，74 单元均分 70.2703%/64.4144%。此 B 在 F 开发评分前就固定，不能解释成事后按 gold 逐题挑专家。与旧 R1 相比，M4 略升而 M5 下降，两个控制都保留。

同工具单 agent 旨在区分“更多工具”与“多专家结构”。首版把不用的索引重复展开，预检首请求达到 248436 tokens；去掉不需要的重复索引后保留原消息。真实 smoke 和 r2 仍遭动态工具参数/原生答案截断，完整开发首错停止。另拟按各工具采用 profile 执行的控制又有容量问题，没有完整双骨干成绩。因此不能拿不完整控制宣称 CF-MoA 已经等资源优于单 agent。

A2 固定同 facts 政策提供了更清楚的小范围证据：9 个规则适用输入，完整支持重算两骨干各 8/9；同覆盖恒 None 各 2/9；失效即删为 3/9、2/9；重算后只删不新增为 4/9、2/9。7 个实质答案侧完整重算全对，说明允许补入并检查剩余路径在这些题上必要。原 R2 范围其实只有 7 输入且含 2 不适用，不能删掉它们后只报覆盖内成绩。M5 模型执行控制又被新增严格 parser 拒绝了多余 None 键，而历史 parser 能接受同一响应，这属于适配变更，后来恢复历史语义；不能靠更严格新包装使控制失败，再证明程序优越。A5/F 及控制

5.5 互补上界：有无必要在弱新专家上继续做聚合

互补分析读取每骨干 121 输入、40 家族、157 评分映射及 74 非参考单元。A2、A3 和 F 覆盖分别 9、8、104，彼此不重叠；它们的正确集合逐题就是 B 的 87/82。A4 在该临床面板没有给定模型，因此 0 覆盖。基本组合的作用首先是能力覆盖分工，不是同题多人协作。

保存输出的离线上界；每骨干 n=121	M4	M5
采用 A2/A3/F 来源集合	87	82
再加入未采用 A1 r5	90	86
仅 B 与旧 R1 两控制联合	91	89
五角色来源及两旧控制全部联合	93	90

oracle 知道每题谁正确，只用来估计候选空间。加入 A1 比 B 多 3/4 题，考虑两个旧控制联合之后只另增 2/1 题，且集中少数家族；A1 本身还会误伤正确答案及产生不可用。对 B 的上界增量区间包含 0，说明可追求的空间小且不确定。真实在线 router 不获得这些 gold 选择信息。分析、后来原样重放与独立计数核验均已完成，不是仍在等待的计划。互补分析及逐题来源

5.6 生成聚合为什么经历这么多版本

最初聚合接收完整原题及保存的 AgentProposal，输出各提议采用/拒绝原因、冲突、至多一次检查和完整原生答案。失败逐步暴露外层合同、解码器与模型生成的相互作用。第一版即使 JSON 完整也可违反跨字段语义；加入 “请求检查必须有冲突” 的约束后，原生解释和自由理由仍反复生成。紧凑 JSON 只减少结构空白，不能消除字符串内重复。原因码 v2 把自由理由改成有限码，是新的方法语义，不是纯格式修复；其中 RU 未决必须有真实冲突，也需单独约束。

聚合阶段	实际变化	保存的终态，合两骨干
原 v1 及跨字段约束	完整提议理由、冲突与原生回答	初 10 题先语义失败；修订后 3 完成/1 截断/6 未提交
紧凑序列化	仅减少结构空白	10 题 8 完成/1 截断/1 未提交
原因码 v2 与 RU 约束	有限理由码、条件依赖	smoke 通过；全 242 为 10 完成/1 失败/231 未提交
简洁原生提示 v3	要求不重复、继续必填字段	全 242 为 58/1/183
先证据后答案 v4	改外层生成顺序	全 242 为 31/1/210
固定 frequency=0.1	唯一预定采样候选	全 242 为 170/1/71
限制空 description	原逻辑下补 decoder 非空约束	默认 A2/A3/F 池全 242 完成
加未采用 A1 缓存与 EOS 对齐	真实双专家试验；统一停止 token 集合	首次 1/1/240，修复后全 242 完成

完整 Unicode 非空白约束两次只在 CPU 阶段失败，没有新模型批次。最后一次无效 JSON 虽然 finish_reason=stop 且没有达到 2048，也不能断言模型自然完成。独立遥测查到 grammar TokenizerInfo 只识别一枚停止 token，而真实引擎会在另外两枚 EOS 停止；对齐停止集合后才继续。修的是引擎/解码停止协议，不是替失败样本补括号。各版原失败、分母、实际费用均保留，没有将中间完成子集拼成主结果。

同预算一词也经修正：逐题参考向量只容纳 245 draws，121 输入每边几乎全是 k=1；少数 k=2 采用先到票破平，最后必然等于 seed42 首答。这不是有效多数票控制。后续固定三 draw 形成完整 726 个逻辑 draw，245 严格复用、481 新生成；称公共预算上限下三次采样，不声称实际花费与聚合完全相等。候选版本表与错误归因

5.7 121 输入完整聚合结果：确实做了多专家，也确实没有胜过 B

完整候选/控制	M4 正确/121	M5 正确/121	M4 原生 ALL/74	M5 原生 ALL/74
强旧 B	87	82	70.2703%	64.4144%
固定三 draw 控制	84	74	65.7658%	59.4595%
实验 A1 池 top-1	72	57	60.7207%	40.6306%
含 A1 完整稀疏聚合	79	74	63.0631%	54.0541%
默认 A2/A3/F 池完整聚合	75	73	56.7568%	54.0541%

含 A1 聚合相对 B 修复/误伤为 6/14、4/12，两个骨干均净少 8 个正确输入。相对实验池 top-1 虽然正确数增 7/17，其中 14/27 来自原不可用被补出，原可评分范围仍误伤更多。因此“比弱池 top-1 高”不能掩盖“低于强旧组合”。默认池聚合和含 A1 聚合连 EOS 协议、专家来源都不同，也不能当干净的只开关 A1 消融。

调用轨迹显示每骨干 29/121 实际激活两个专家：A1+A2 九题、A1+A3 八题、A1+F 十二题；其余 92 单专家，242 次均只做一轮聚合、无追加检查。实际多专家子集正确 14/29、16/29。进一步要求两个专家各有被采用且位置精确的 claim，只剩 M4 七题/M5 四题，正确 1/7、0/4，并存在重复引用。调用两个角色、声称用了两个角色和使用两份独立可靠证据不是同一指标。该结果支持保留协作失败的具体原因，同时不能推广为所有多 agent 都无效。完整结果与证据使用

5.8 增量修订与四轮效果优先：从“审计过不去”走到真实质量检验

先对 B→ 聚合的 36 条变化归因：26 误伤中 24 条已有正确专家候选送达，23 条聚合还自报采纳，问题不只是候选缺失。于是修订为以 B 为基底，只提小范围支持增量；A2 恢复历史 parser，新 B 确定性封装保留 242 答案值，其中旧 M5 d00050 仍不可用。A1_delta 六个诊断 smoke 全部不可用、未进入裁决；A3 关键编辑/随机编辑/原题重评分则真实跑了两骨干全部 8 诊断输入。M4 关键编辑 4/8 与原题重评分 4/8 持平，M5 关键编辑 3/8 低于原题 4/8，未采用。该轮 254 新调用，不能再称 A3 编辑“还未实现”。

用户随后改为效果优先：可选引用/审计失败不自动拦截完整原生答案，普通错误继续完成固定面板，让真实质量决定是否采用。四轮主要结果如下；第一二轮 34 题与第三四轮 34 题不是同一面板，不能纵向相减当同题改进。

轮次与问题	B 正确（M4/M5）	主候选	关键控制与判断
第一轮：轻量 A1 是否能纠正 B	24/34；28/34	19/34；23/34	同预算目标重答 21/21，旧提议自由读出 24/26；新增 A1 没有净收益
第二轮：只裁决一个目标成员	24/34；28/34	19/34；23/34	控制 21/23；直接映射判定又产生 11/10 不可用，未采用
第三轮：真实检索区分知识、一次完整选择	23/34；19/34	21/34；17/34	同资料普通重答 21/17；无新增资料 19/15，资料有局部作用但专家不胜控制/B
第四轮：显式绑定主体/范围/条件，再裁决	23/34；19/34	18/34；15/34	普通 20/14、去理由 20/15；主未胜控制，M4 一题三臂截断

上表控制列的两个并列正确数按 M4、M5 排列，分母均为 34；例如“21/21”表示两骨干各

21/34，并非 21 题全对。

第三轮真实检索四库 BM25 与 MedCPT，共 123 物理检索/126 逻辑 query，提供 M4 232 段、M5 254 段；这不是“没有检索到内容”。但普通控制拿同材料就取得同样正确数，相关知识存在不足以证明专门支持角色使用得更好。第四轮完整提议 126 份都可解析，最终裁决仍会违背提议；唯一修复也拒绝了主提议，所以强迫最终答案服从它同样没有依据。还发现继承的诊断自由字符串没有真正落实有限目录键读出，记录为需另版修正的实现缺口，不补映射追改旧分。

新 A5 在完整 121 上得到 89/83，比 B 多 2/1，但同触发普通重答也 89/83。简单 NLI 八题各臂全对；更难 Scope32 的 F 两骨干 31/32，新 A5 为 30/32、31/32 且与普通重答完全相同。故有局部重复作答收益，却没有建立新抗干扰机制特有增量。A3 第二轮固定原题双候选比较 2/8、3/8，也低于原目录 3/8、4/8。四轮合 2203 真实生成、17716744 输入/160997 输出 tokens；原全过程报告第 11 章的 254 次及更早开发成本另列。这些失败约束后续设计，而非要求继续无止境扫提示。报告 §11–13

5.9 最简 B：保留有效能力，五操作有精确可执行含义

09-23 用户新计划取消全局生成改答，沿用目录、规则、条件模拟及 F。采用身份固定为 `adopted_B_five_operations_v1`，不是今天按最终成绩拼出来。真实优先级是：诊断格式 →A3；规则资格 →A1/A2 共享核；完整可执行模型 →A4；支持的 single/robustness_single/relation 且有原消息 →A5/F；否则完整原答案透传。在线不读 R 标签、gold、来源 ID 或另一端。

规则支路一次抽 facts、一次执行三值规则，再导出两个角色的操作轨迹。设 S0 为初选集合，M 为成立支持，C 为矛盾，U 为未知，A1 补入 M−S0，A2 撤销 C∩S0 并处理剩余支持；普通合法集合下与 M∪(S0∩U) 等价，最终仍交旧 assemble 处理 None 独占、非法初答、无可输出实体、例外和范围。某路径失效不会删除另有 MET 路径的选项。初 121 回放仅有补入记录而无撤销，并不证明 A2 没有撤销功能。

后续在完整 123 规则输入做同 facts/status/paths 消融：M4 完整 69 正确，禁 add43、禁 remove53；M5 完整 71，禁 add48、禁 remove60。不可用 1/14 仍在 123 分母。这个结果直接支持正向补入和负向撤销都有效；它不是两套模型的协同证明。全 v5 每骨干目录 3560、规则 123、F10178、透传 44，共 13905；A4 临床覆盖 0。A4 旧 24 个新虚拟 profile×12 题的 288 数值全对，是给定模型专项，不能换掉临床 R4 结果。F 旧 208 单元及七系统 R1–R3 开发收益是组件来源；全系统运行范围、随机输出和状态检查不同，不能把旧 head 表的整数强行等同后期 B。

当时只保留一个新开关：F 实际路径/样本出现至少两个合法语义键时，再普通重答一次，否则复用 F。该开关不影响诊断/规则/模型分支。旧 seed42 复用，补固定 43/44；另从已暴露 F 历史池取自然 52 输入/18 原生单元、18 家族。自然面板不是盲测，也不是新确认 D。最简实现与等价回放、123 消融

范围/骨干	B 正确	seed42	seed43	seed44
历史 121 / M4	87	89	88	88
历史 121 / M5	82	83	84	84
自然 52 / M4	35	34	31	32
自然 52 / M5	26	25	23	24

231 新调用完成且无新增运行失败，说明自然退步是保存的质量结果。旧 121 每骨干三 seed 均小幅净增，但自然 52 六格均下降；平均自然原生均分下降 6.296pp。家族 bootstrap 对旧 121 和自然 52 差值均跨 0，所以不说总体效应已确定为负，而是按采用标准没有稳定增量，默认关掉

普通重答。旧 121 四个应变配对曾被早报告误写成多选，后核实是诊断、均不属 F 支持；自然仅两应变控制，也不能用来宣称已广泛验收抗干扰。

5.10 95 触发组合诊断：RCV 为什么转向选择旧候选

用户要求补齐源码与真实样本后，离线导出历史 M4/M5 28/26、自然 25/16，共 95 个题目—骨干触发组合，连同 F 已有路径和三 seed 共 285 补充回答。旧池 78/95 已含正确键，其中 35 组 F 未选中，17 组所有旧候选都错。285 补充答的 35 次修复全部取回旧池已有正确键，40 次误伤中 39 次选了旧池已有错误键；新增正确键覆盖为 0。这说明该面板主要矛盾是候选选择，不能由此推断所有未来生成都无新增信息。

核查没有证实退步由标签映射、softmax、消息丢失或评分键错绑造成；保存请求包含原上下文和合法题面。明确观察到年龄/病程错绑、结局范围混淆、解释与键冲突，但不能将 31 组原文审阅泛化为全部医学错误根因。7 个 NLI 组合的概率路径和 88 个普通生成票分开，不能把非零概率都当实际生成候选。触发组不是完整 121/52 的新分母，非触发题也没有同样普通重答反事实。

据此，后续最小变化是保持旧池，核验每个已有合法候选能否回答当前问题。C2 不给旧理由；C3 给同候选对应的旧完整理由，并明确标为不可信模型意见。每候选用两次 A/B 映射：一次 A= 真，一次 B= 真，对两码 log-prob 各自 softmax 后取 TRUE 概率再平均，选分数最大者；平局先回旧 F 键。选择完整旧响应，不编造新的患者事实，不把核验分数当已校准医学概率。NLI 沿用旧 F 专门路径，普通 F 分歧才进入扩展。95 诊断、RCV 算法及实际入口

5.11 RCV 有限开发：理由有真实选择信号，也有明确误伤

候选验证使用原 Llama3.1-8B 与 Qwen3-8B，score 入口 temperature=0、max_tokens=1、两码受限；F 生成 profile 仍 0.7/42/2048，不能把 score 配置说成把采用 head 温度改零。实际 780 次取分、190 条执行输出，对完整 121/52 补齐两臂。此前 32 次 score 尝试均止于引擎初始化，0 模型提交；原失败、恢复及两处离线接口修正保留，没有因此重生成 F。

每格：正确输入数；原生非参考 ALL	历史 M4（121/74）	历史 M5（121/74）	自然 M4（52/18）	自然 M5（52/18）
B/F	87；70.27%	82；64.41%	35；60.37%	26；49.26%
旧池 + 3 份已存重答控制	89；71.62%	83；66.67%	35；62.22%	26；53.70%
C2 无理由	87；68.92%	83；63.96%	33；61.48%	27；52.59%
C3 带理由	88；71.62%	87；68.92%	35；66.67%	28；48.15%

88 个普通候选组合中 71 含正确键，B 和 C2 均选中 38，C3 选中 46；C3 合 17 修复/9 误伤，净增 8 个输入。这是值得扩大到完整 v5 检验的正信号。自然 M5 正确 26→28 但 ALL49.26→48.15 并非算错：两处修复分别使 M22 单元 +0.4，另一个独立 M11 单元 −1，18 单元等权合 −1.111pp；一些参考端修复不进 ALL。自然保持双正确又从 17/10 降为 C3 的 16/9，而历史为 48→47、44→46。不能只取输入计数宣布稳定胜出。

反例中，有正确键在池内却被核验高分错误替代；某例错误候选均分约 0.985，旧理由已读到 NOT，不能捏造为 “漏看否定”。理由有时帮助有时误导，A/B 互换也未消除全部编码偏差。因此默认 B 仍不变，C3 作为主研究扩展进入全量六臂。完整开发结果与反例

5.12 六臂全 v5 如何闭环

全量定义 C0= 原 MedRAG 初答，C1=B，C2= 同池无理由验证，C3= 同池带理由验证，C4= 旧池加三份实际补充回答，C5= 同池同理由整体选择。C4 的三答在全量确实新执行，不是凭空把开发缓存当全量；C5 用整体候选比较区分逐候选验证的作用。每个骨干每臂固定 13905 输入、15616 原生评分映射、6104 非参考 ALL 单元、4766 家族。模型只看当前输入，reference/变化端分别推理；保持和应变关系仅离线计算。

最初每骨干 F 仅 717 输入可精确复用，9461 池缺失。薄 cached 入口先回放 190 完整输出和 780 请求，live 每骨干七种路径连通；固定前 16 个 F 输入自然出现分歧，随后完成剩余目录和 F/六臂。实际分片只按既定输入和资源安排，不能按 gold 或结果选择成员。M4 旧 GPU1 任务在边界 STOP 后分到 GPU1/3，39 已完成 callback 精确继承；M5 停止段后分三卡，36callback 继承，两次 GPU2 初始化失败均 0 新物理调用。原监听 JSON 读取错误仅能确认读取失败，半写文件是可能原因而非已证根因；有界重试恢复后只补一次 CPU 汇总。

M4 于 09-26 11:19:48 完成全量评分，M5 尾片 15:18:41 结束，15:19:42 完成评分。失败目录、非法 F 内部票、原不可用和旧分片并集均保留；没有缩短上下文、降低精度、改 seed 或补抽坏票来换取完成。09-28 再做全量分层、家族区间、费用归属和五表收尾，不新增推理/评分。下面所有表都属于该已完成范围，而不是 09-25 部分进度。完成过程及故障恢复

5.12.1 完整六臂总体与 R1–R5

以下均为百分数，ALL、R1、R2、R3、R4、R5 分母依次为 6104、2866、79、733、13、3600 个原生非参考单元。类别可重叠、R3 属于 R1，不相加；C0 与 B 使用相同原生评价范围。表由冻结 all_category_results 逐行转写，未重新评分。

骨干 / 臂	ALL	R1	R2	R3	R4	R5
M4 / C0	48.1990	27.8437	29.1139	30.4229	53.8462	65.2796
M4 / B	58.2924	44.6267	48.1013	53.2060	53.8462	68.8380
M4 / C2	55.9939	43.7893	48.1013	52.1146	46.1538	65.6074
M4 / C3	56.4815	44.8709	48.1013	52.7967	30.7692	66.0454
M4 / C4	58.3219	44.8709	48.1013	52.5239	38.4615	69.1102
M4 / C5	56.7295	44.8011	48.1013	52.3874	38.4615	66.4935
M5 / C0	47.3487	28.5764	41.7722	25.2387	53.8462	63.4213
M5 / B	59.3616	46.6155	58.2278	60.0273	23.0769	68.7898
M5 / C2	59.3562	48.4299	58.2278	60.0273	30.7692	68.3917
M5 / C3	60.2889	49.0230	59.4937	60.3001	30.7692	69.6954
M5 / C4	59.6723	48.1507	58.2278	60.3001	38.4615	68.9278
M5 / C5	58.9690	47.8716	58.2278	59.8909	30.7692	67.9852

B 相对 C0 的 ALL 增量为 M4 +10.0934pp，家族 95% 区间 [8.9580,11.2340]；M5 +12.0129pp，[10.9177,13.1510]。这两项是完整采用系统的核心成果。C3 相对 B 为 −1.8108pp [−2.5287,−1.0819] 和 +0.9273pp [0.3039,1.5562]，跨骨干方向不同；相对 C2 为 +0.4877pp [−0.1275,1.0907] 及 +0.9327pp [0.4641,1.4010]。这些区间是 5000 次、seed240924、同臂共享家族抽样的已暴露开发描述，不消除此前选择或多重比较。不能把 M5 C3 和 M4 B 拼成一个新采用身份。

5.12.2 输入正确、不可用、修复及两端同时正确

臂	M4 正确/13905	M4 不可用	M5 正确/13905	M5 不可用	M4 保持双正确/6838	M5 保持双正确/6838	M4 应变双正确/1780	M5 应变双正确/1780
C0	7441	0	6913	0	4005	3528	13	27
B	8924	51	8971	22	4440	4460	347	360
C2	8554	51	8843	22	4139	4381	347	360
C3	8649	51	9060	22	4144	4486	347	360
C4	8951	157	8878	86	4509	4412	347	360
C5	8660	51	8739	22	4150	4246	347	360

B 同时改善保持和应变：M4 保持 +6.3615pp、应变 +18.7640pp；M5 保持 +13.6297pp、应变 +18.7079pp，四个家族区间均为正。应变绝对双正确仍约 20%，不能称已解决医学 CF。C2–C5 都不改变目录分支，应变结果逐项与 B 相同；零差值表示该固定输出没有改变，不是所有系统应变能力为零。C0 不可用 =0 只代表有保存输出，和评分有效/正确是不同概念。

相对 B，C3 在 M4 修 436 伤 711 净 −275，在 M5 修 452 伤 363 净 +89；C4 分别修 319 伤 252 但 40 个 B 正确变不可用，净 +27；M5 修 275 伤 341 且 27 个正确变不可用，净 −93。计数应使用 “修复 − 误伤 + 不可用转正确 − 正确转不可用”，不能遗漏失败造成的损失。主答案提高也不保证辅助纠错字段：每骨干 2700 条 robustness 辅助映射，M4 的 errors exact 从 B 的 55/2700 降至 C3 的 51/2700；M5 则从 425/2700 变为 427/2700。全部质量与辅助表

5.12.3 所有 11 来源：展示异质性而不只选赢家

每格是该来源原生单元均分（%），每行分母为 units。M01 MedEinst、M02 MedPIC、M06 HIV 场景、M10 CPV、M11 Cultural Cues、M12 AMQA、M14 DiversityMedQA、M17 MedPerturb、M20 MedCounterFact、M22 MedRGB、M23 BioRAB。同一来源可含多个 R 标签，来源单元仍只计一次。下表保留 132 个骨干 × 来源 × 臂观测。

骨干 / 来源	单元数	C0	B	C2	C3	C4	C5
M4 / M01	1780	13.2584	35.6180	35.6180	35.6180	35.6180	35.6180
M4 / M02	167	28.7425	53.8922	53.8922	53.8922	53.8922	53.8922
M4 / M06	13	53.8462	53.8462	46.1538	30.7692	38.4615	38.4615
M4 / M10	451	68.7361	69.6231	65.1885	64.5233	70.0665	67.6275
M4 / M11	517	67.3114	70.0193	66.9246	68.4720	70.0193	69.4391
M4 / M12	584	61.4726	66.7808	60.2740	60.9589	64.2123	59.5890
M4 / M14	454	72.2467	72.9075	70.2643	65.6388	72.0264	66.9604
M4 / M17	450	87.4815	91.1481	84.8148	88.6296	91.8148	88.0370
M4 / M20	788	51.0152	55.3299	54.3147	57.7411	57.3604	57.8680
M4 / M22	450	69.2000	72.0000	68.2667	68.1778	72.4000	67.9111
M4 / M23	450	44.2222	57.7778	57.7778	57.7778	57.7778	57.7778
M5 / M01	1780	10.8989	40.3371	40.3371	40.3371	40.3371	40.3371
M5 / M02	167	38.3234	58.0838	58.0838	58.0838	58.0838	58.0838
M5 / M06	13	53.8462	23.0769	30.7692	30.7692	38.4615	30.7692
M5 / M10	451	65.8537	65.8537	64.5233	68.7361	67.4058	65.1885
M5 / M11	517	68.6654	70.5996	67.3114	66.7311	70.4062	68.8588
M5 / M12	584	64.0411	63.0137	60.7877	60.9589	63.0137	61.8151
M5 / M14	454	67.4009	69.8238	68.7225	68.0617	67.8414	68.0617
M5 / M17	450	76.2593	81.5185	78.7778	83.7407	76.2222	73.9259

骨干 / 来源	单元数	C0	B	C2	C3	C4	C5
M5 / M20	788	56.2183	53.0457	60.6599	62.6904	58.7563	58.2487
M5 / M22	450	52.8889	74.1333	72.3556	73.3778	73.8667	73.0667
M5 / M23	450	59.7778	75.5556	75.5556	75.5556	75.5556	75.5556

来源表用于判断谁贡献总体收益、哪里仍退步，不提供按来源 ID 在线选赢家的权限。例如临床 R4 只有 M06 的 13 个单元，模型内 A4 不能替代其分数。M17/M22/M23 等一单元可有多个非参考映射，因此不能把本表均分和下一张输入正确率混为同一指标。冻结来源结果

5.12.4 全部 5 输入格式

这里明确改用唯一输入正确率，包含 reference 输入，分母不是原生非参考单元。每个骨干五格式输入数之和 13905。保留 60 个骨干 × 格式 × 臂结果，不能挑某格式上升替换 ALL。

骨干 / 格式	输入数	C0	B	C2	C3	C4	C5
M4 / diagnosis	3560	9.4663	38.0056	38.0056	38.0056	38.0056	38.0056
M4 / multi	167	28.7425	53.8922	53.8922	53.8922	53.8922	53.8922
M4 / relation	989	52.7806	55.2073	55.9151	59.1507	58.0384	59.1507
M4 / robustness_ single	2700	69.5556	71.9630	68.7778	68.6296	72.4074	68.2593
M4 / single	6489	71.7522	76.9302	72.4457	73.4782	76.7299	73.8018
M5 / diagnosis	3560	9.4944	42.6685	42.6685	42.6685	42.6685	42.6685
M5 / multi	167	38.3234	58.0838	58.0838	58.0838	58.0838	58.0838
M5 / relation	989	59.4540	55.6117	62.2851	64.0040	60.1618	59.8584
M5 / robustness_ single	2700	53.0000	74.4444	72.7407	73.9630	74.0370	73.5556
M5 / single	6489	69.2248	73.8943	71.6135	74.1871	71.9371	70.0416

格式冻结结果同时保留每格 correct 及 unavailable 整数。本篇百分比只用于可读展示，精确整数和未舍入值仍可直接定位。

5.13 成本、覆盖和失败分母

162979 是完整 v5 这一交付中 19 个 SQL 来源去重后的新物理请求，共 957810324 输入、18291906 输出 tokens，M4 87429、M5 75550。它不是从项目最初数据构建、七基线、148 阶段 head 到所有 CF-MoA 失败的项目总成本，也不能除以六当每臂平均费用。各方法归属共同 B 一次再加本臂费用，跨臂重复显示的共同 B 不能相加成实际支付。共同历史检索/C0 上游费用不完整，明确 unknown，不是免费。

骨干	臂	共同 B 请求	追加请求	归属请求小计	输入 token	输出 token	已知完整输入行模型秒小计	时间未知输入
M4	C0 原方法	unknown	unknown	unknown	unknown	unknown	unknown	13,905
M4	C1 / B	59,800	0	59,800	241,675,469	9,686,224	79,034.585	2,503

骨干	臂	共同 B 请求	追加请求	归属请求小计	输入 token	输出 token	已知完整输入行模型秒小计	时间未知输入
M4	C2 无理由验证	59,800	13,314	73,114	351,246,487	9,699,538	112,782.426	2,503
M4	C3 带理由验证	59,800	13,308	73,108	358,643,985	9,699,532	112,725.215	2,503
M4	C4 旧池+三答	59,800	9,249	69,049	322,001,841	10,920,032	105,555.743	2,503
M4	C5 联合选择	59,800	5,922	65,722	292,229,677	9,692,146	94,193.783	2,503
M5	C0 原方法	unknown	unknown	unknown	unknown	unknown	unknown	13,905
M5	C1 / B	58,301	0	58,301	220,580,598	7,645,205	74,024.742	2,503
M5	C2 无理由验证	58,301	9,820	68,121	289,954,660	7,655,025	95,023.691	2,503
M5	C3 带理由验证	58,301	9,820	68,121	294,927,306	7,655,025	94,696.076	2,503
M5	C4 旧池+三答	58,301	7,049	65,350	273,665,097	8,518,259	90,047.760	2,503
M5	C5 联合选择	58,301	4,574	62,875	254,514,960	7,649,779	83,499.809	2,503

表中请求是上游 C0 之外的 head/readout 归属。每骨干每臂 2503 输入历史模型时间未知，只有 11402 输入的完整已知事件秒可报告小计；事件和不等于独占 GPU 时间、端到端延迟、能耗或人民币费用。147 条跨 run replay 对应 75 唯一原 callback，最终行 new_execution 比 SQL 少 39/36 正是迁移前已付前缀，已逐字段对账，不能重复计费。

普通 F 每骨干 9293 输入，NLI885，合 10178。普通 F 且合法不同键 K≥2 的覆盖为 M4 2964/13905（21.3161%）、M5 2295/13905（16.5049%）；M4 保留其中 2 个 B 不可用。范围内旧无效 F 票 M4 533、M5 186 全部保留。C3 真实激活 2962/2295，其中 M4 一例、M5 八例技术失败按既定合同返回已存 F。M4 C2 比 C3 多 6 个请求，来自同题 C3 容量检查失败前未调用，不能说带理由天然更省。C4 追加生成造成更多不可用，M5 八例调用前失败经 SQL 证明 0callback，追加成本 0 但失败仍在分母。

这些账本使论文能够同时陈述系统收益和获取收益的计算代价。缓存与跨臂共享降低本轮新增运行量，但部署方法所需历史 F/旧 head 成本仍要归属；反过来，缓存回放次数不能冒充新模型调用。完整费用及机制覆盖

5.14 完成了什么，为什么还保留未完成项

截至 09-28，采用组件集成、真实五操作路径、两骨干完整六臂推理/原生评分、全部来源/格式/类别分层、36 个家族区间、每方法成本和五表已经完成。数据/标签没有因输赢调整；有限已知证据没有确立 full-v5 可剔除的客观缺陷，数据问题清单为空。空清单不代表全面临床真值重审，M20:255 参考可靠性等仍须按原记录裁定，不能依据某臂表现删题。

共同冻结后的新家族确认和第二独立 F 池没有实际运行。准备曾列 128 母题、512 端点/骨干，其中 448 普通 F 和 64NLI，另 8 个已暴露作者控制的 16 端单列；第二普通 F 池计划 seed142–146 对应旧 42–46。成员、暴露、复用政策、driver 及分析准备存在，不等于结果存在。自然 52 的 M4 C0 四缺项后来补齐，35/52、ALL54.8148%；M5 四旧缺项仍未跑，保持 48/52 partial，不能借别臂或不完整子集填完整分。完整同工具单 agent 与预算曲线也未成为可用主控制；更广临床 R4、跨模型后果能力仍未验证。

作者可以据现有材料写出三层有证据贡献：用五操作体系组织问题并暴露系统不足；采用规则支

持、目录决策、条件模型执行和稳健读出的真实功能设计；在完整 v5 上取得两个骨干 ALL 及保持/应变的系统改善。可以进一步解释为什么原生成聚合、重答和候选验证未必超过已有稳健选择。不能据 B 收益宣称独立五专家协同已被证明，也不能因 RCV 在 M4 退步而否定 B 的实测收益。既有组件检查和新系统的最终独立确认属于不同证据层，不互相抹去。

5.15 复查导航与可复现边界

作者要复查某个阶段，先用持续主记录/全过程报告中的锚点定位冻结运行包；不要运行旧脚本覆盖原收据。算法源码入口为 `cf_moa/controller/minimal_operations.py`、`strong_legacy.py`、`moa_rcv.py` 与 `agents/a5_candidate_verify.py`，但历史实验须使用各 run 绑定的源码版本。原始题文、messages、完整响应、SQL 和 gold 可能仅保存在本地或受限包；此前公开元数据不等于完整医学语义 trace。当前 GitHub 为私有，所有分享需遵循原数据许可和已有访问权限。

本篇附表读取 09-28 冻结 JSON 后只做百分比展示；没有调用 grader，也没有重新产生区间。复查全六臂数据可用完整表入口、统计输入与脚本、最终状态。本篇阅读覆盖、来源哈希和生成表格核对见CF 篇核验收据；它明确本轮阅读与复用既有审计的边界，不声称再次通读全部原始大日志。

六、把实际研究变成作者共同认可的逻辑链

6.1 三个研究层次怎样连接

数据层先回答“哪些变化影响了哪个判断”。五类标签是对任务的功能描述，既容纳新增证据后的应变，也容纳无关扰动下的保持。构建层把这种描述落实成具有出处、目标、资格、评分和抽样沿革的 benchmark，让方法之间的比较有共同对象。方法层再回答“当前输入需要什么计算能力”：支持重算、候选比较、显式模型执行或稳健读出。R 标签用于解释数据与评价，agent 能力用于在线执行；二者通过研究设计联系，不通过隐藏标签直接路由。

因此，论文中的因果论证不能写成“R3 低，所以必然缺某一内部神经机制；添加 A3 证明已经解决医学推理”。已有证据能支持的链条更具体：R3 等子集整体表现较弱；错误检查发现大量候选不可达或原生映射失败；给相同骨干和上下文提供公开目录后，多个系统的有效决策改善；用名称规范、单次目录、投票和校正分开观察后，主要收益来自候选空间和读出，额外校正并不稳定。这个结论有实际机制解释，也有清楚的可复现操作。

R2 的链条与此类似但不同：撤销一条条件后，需要重新计算所有仍适用的支持；自由生成整张支持图、逐药审计或全盘重答不稳定；有限规则与正向事实提取让执行可检查；增加支持与撤销支持消融均影响结果。不过总体类别偏斜使恒 None 成为很强的控制，所以必须同时看仍有支持的案例，才能解释我们想保留的能力。不能把 R3 的目录收益套用成 R2 的规则机制，也不能因一个简单控制总分更高就抹掉已经测得的剩余支持识别。

R4 和 R5 则补全框架对两种不同需求的处理。R4 说明在关系和模型确实已给定时，局部干预表示能够可靠驱动已知求解器；它不补造未知医学因果模型。R5 说明保持正确需要受任务约束的稳定读出，同时必须保留对相关变化的响应能力。它不允许复制隐藏参照答案。每条分支解决的对象不同，适用性、覆盖和证据成熟度也不同。

6.2 可以直接供作者讨论的一段完整故事

> 医学反事实推理要求系统识别条件变化对具体判断的影响：有些变化引入新支持，有些使旧支持失效，有些改变候选之间的相对证据，有些需要沿已知关系推导后果，还有一些不应影响当前目标。现有医学反事实与扰动资源分散在不同任务和数据集之中，单独报告来源级分数难以揭示这些不同功能需求。我们首先整理相关资源，以五种可解释关

> 系对原生问题和具体目标重新组织，并通过出处核验、资格审核和可复现抽样构建跨 11 来源的 benchmark。在七个系统配置上进行完整评价后，我们发现整体成绩掩盖了支持更新和候选重比较子集上的明显不足。围绕这些观察，我们研发并验证了一组专门 head，将有效的支持处理、候选决策、条件后果执行和保持读出组织为 CF-MoA 的五个功能 agent。最终采用版通过输入能力路由选择适用操作，保留原生答案合同，在两个骨干的完整 benchmark 上同时提高总体得分、应变与保持表现。组件对照进一步说明哪些收益来自规则作用域、候选可达性和任务适配读出，以及何时更复杂的聚合不能带来额外改善。

这段叙述足以把数据与框架放在同一研究问题下。它没有把原始多专家聚合目标冒充已获证实，也没有把后期某个验证器当作全部方法。真实研究中的失败不是正文的主角，但它们解释了我们为什么采用现在的组件。

6.3 四项贡献分别有什么证据

拟强调的贡献	已完成的具体工作	能直接支持的证据	需要保留的边界
功能 taxonomy	对变化—目标关系定义 R1–R5，保留多标签、关系理由、证据与不能推断内容	分类规则、具体正反例、实际纠错、跨来源类别统计	不是五个训练分类器，不声称穷尽医学因果推理
可追溯 benchmark	来源登记、原件归档、目标级审核、执行资格、原生物化、冻结抽样和版本沿革	26→15→55,991；合格 38,123/77,781；v5 6,104/13,000/11 来源；重放与来源审计	归档量不等于可评题量；来自既有来源且有开发暴露
跨系统诊断与 head	七配置完整 v5；R1–R3 三个功能子集的末端改进及组件对照	42 个基线值、21 组正向前后差、原评分一致性核查、外部和合成控制	七配置是六家族；类别重叠；部分规则事实采用两骨干共享生成与离线组合
CF-MoA 系统设计与评价	五功能角色、明确能力路由、异构组件、原生输出、失败回退及扩展对照	双骨干完整 B 收益、保持/应变、123 操作消融、完整六臂/来源/费用账	A1/A2 共享；A4 临床 v5 零覆盖；没有完成最终新家族确认或证明全局协同增量

贡献不必每一项都是全新数学算子。对既有工具的有效组织、可解释的数据视角、可复现的运行协议和有对照的经验发现，都可以被清楚陈述。相应地，不能把目录、标准数值求解器或普通多样本多数票本身说成原创算法。用户希望把结果写得有吸引力，最有说服力的方式是突出这些真实且相互支撑的成果，而不是把多个不兼容协议下最高的数字放在同一张表里。

6.4 哪些已有数据优先放正文，为什么

正文首先放完整同范围结果，再用最能解释机制的对照分面。后续扩展不是因为不利而删除，而是按对中心问题的贡献安排层次。下面是作者写作时可以直接使用的选择规则。

数据面板	选用理由与有利信号	建议位置与配套信息
当前 v5 完整七基线 + 双骨干 B	固定 6,104 单元、全 R 类；B 为同一个既有采用版本，ALL58.29/59.36%，相对对应 C0+10.09/+12.01pp	主结果表九行；保留 R4 小样本下降、M3 较高 R5 与所有类别

数据面板	选用理由与有利信号	建议位置与配套信息
完整保持/应变配对	两骨干应变 13→347、27→360/1,780；保持 4,005→4,440、3,528→4,460/6,838；直接对应 “该变则变、该稳则稳”	主图或主表；说明双端独立推理，仍有约 80% 应变配对未双正确
全七系统 R1–R3	21 组净提升，证明末端能力并非只适用于一个底座；R1 范围还包含 R3 之外的新增单元	主文广度结果；不能把 3,678 成员当独立样本，不能改称七条完整 CF-MoA 链
123 条支持操作消融	两骨干禁 add 或 remove 均下降，直接对应两个支持角色的作用	主机制表；共享核、规则覆盖、未引入新事实保持可见
680 诊断控制	单目录已提供多数增益；完整七行比挑单个系统更有解释力	主文简表/附录全表；同时给未校正与校正，避免将整体收益全记给校正
R2 剩余支持 9 例及全 79 控制	揭示恒 None 高总分掩盖的能力丢失	必须与 R2 总体一起解释；九例不能替代全 79 结果
A4 24×12 新 profile	给定模型下 288/288、优于同工具整计划的 270/222 联合数值	独立组件面板；不塞入临床 R4 列，不称新患者外部验证
R5 208 及新 16/8 检查	正面展示旧 F 真实收益与有限冻结后检查	组件结果；208 的阶段组成、旧 192 相对 Maj5 小增量保留
ASCENT/CUPCase/规则探针	支持接口可用性、来源扩展或执行机制的具体边界	各用自己的分母与版本，不合成一个 “外部准确率”
全部六臂 C0–C5	解释为何采用 B、候选验证在哪个骨干有增量，以及增加采样是否值得	扩展表；C3−B −1.81/+0.93pp 完整保留，不拼接不同骨干最优赢家
旧 121 与自然 52 真实聚合/修订	展示研发选择并非停留在接口包装，确实试过更复杂组合	方法设计分析/附录；保持历史分母、缺项和版本差别
旧 WM/Adapter 与全来源早期结果	解释输入合同、机制对照和分类动机的来历	研究史/附录；旧 80% 以上四选项分数不与 v5 开放诊断混排

相对七基线最高 ALL51.6082%，两个 B 的描述性优势为 6.6841 和 7.7534pp。这可以作为统一评测下的系统结果，但上游资源、输出约束与调用数不相等，现有资料不能把这个差直接解释为同预算纯算法因果效应。更扎实的主比较是各自 C0→B，并配合机制控制。

6.5 有吸引力且能被证据支持的写法

作者可以强调 “统一的功能视角” “跨来源、目标级、可追溯 benchmark” “从功能诊断到操作专门化” “跨七配置的末端改进” “双骨干全量系统收益” “同时改善应变与保持”。这些表述都能定位到真实工作，而不是仅有计划。

几个需要精确限定的词同样重要。“五 agent” 描述五个操作角色；“多 agent 协作带来增益” 需要比单专家、同工具、同预算等控制更强的证据，目前不能直接给出。“验证” 可以指已经完成的规则、病例或生理 profile 组件检查；“最终系统独立确认” 则尚未执行，二者不要互相抵消。已见 v5 反馈后获得的开发提升是实测成果，只是其泛化证明力与新家族确认不同。没有必要把每次可观测改进都贬成无效，也不能用 “已冻结” 抹掉更早暴露。

推荐论文题目沿用：**CF-MoA: Taxonomy-Guided Benchmarking and Agent Orchestration for Counterfactual Medical Reasoning**。此前英文框架可以作为成文组织起点；本底稿提供其完整研究材料。正式论文应由作者根据贡献主次压缩，本底稿保留他们作出这些选择所需的事实。

七、截至当前的完成状态、空缺与复现边界

7.1 已完成、停止和未执行分别是什么

对象	当前状态	不应混淆的历史措辞
来源、五类体系、v4 资格与 v5 抽样	已完成本轮定义的收集、审核、构建和重放，缺失来源/资格另有台账	“26 候选” 不等于全部取得；“全量覆盖” 指档案去向，不等于全都可评
七系统正式 v5	已完成，包含 M6 MedGENIE 与 M7 终态	09-13 旧快照中的暂停 52/1,646，不是当前两系统仍未完成
七系统 R1–R3 head	已完成相应开发实验与交付，21 组净提升	不需要所有组件独立获益才能承认整体提升；不等于新独立系统确认
R4	临床扩展未采用；给定模型局部干预分支与新 profile 检查完成	原 13 题与模型 288 题各保留，不替换
R5	旧 F 交付完成；后续 W/X/Y 等未达到采用条件	新 CAD 五头是另外的研究计划，不能误认本项目 A1–A5 均已训练
五角色 B 及全 v5 六臂	已完成；B 仍为采用默认，后续 C3 按骨干出现不同方向	B 包装与旧有效组件等价，本次包装本身没有凭空创造额外准确率
全量来源/格式/区间/成本/五表	09-28 收尾完成	09-26 报告所写 “尚缺这些表” 已被后续完成记录覆盖
最终新家族独立确认、第二独立 F 池	未执行/延后	不能因为材料已准备、CPU 测试通过或预算有余，就写成模型已完成验证
自然 52 中 M5 C0 旧缺项	保留 partial 历史，四旧缺项未补齐	不补造一个完整 C0 来做未经执行的比较
当前作者底稿与之前论文文件	底稿为作者研究材料；旧完整稿与新框架另存	文档完成不等于新实验完成，也不等于正式论文已投稿

7.2 为什么不同记录看起来会矛盾

第一种是时间变化。全过程报告保留了 “首错停止” “尚未完成” “等待处理” 等当时状态，后面章节可能已有修复或完成。读者应按版本和日期查后续闭环，不能用最早一段覆盖整条方法的发展。第二种是对象变化。M6 先指 i-MedRAG，后来正式七配置中的 M6 改为 MedGENIE；来源 M06 则一直是数据来源，不是该方法。第三种是协议变化。旧 paired 四选项、v3 互斥类别和 v5 多标签原生评测不是相同任务。第四种是统计变化。正确输入计数、native ALL、类别均分和 pair 两端正确率可以同时不同，不能从某一项推算其余所有指标。

第五种是采用身份与研究候选混写。独立 A1、新 A5、A3 编辑、F 额外重答开关和候选验证都实际尝试过，但未必进入默认 B；旧有效 A3/F 仍可被默认使用。第六种是工程准备与真实执行混写：CPU fixture 或合成 response 验证可以证明接口行为，不能算新增医学推理证据；原始模型输出的严格缓存复用则属于合法已有证据，但不是新模型调用。这些区别直接决定作者怎样描述 “我们做了什么”。

7.3 工程与资源信息对研究结论的作用

代码不在一个统一 Git 根内。`/home/data3/txy` 是共同实验工作区，MedRGAG、MA-RAG、MedRAG 适配、各日期运行包和 CF-MoA 源代码分布于不同目录。研究持续记录统一在 `docs/`，日期目录保存冻结配置、日志、预测、评分和运行包。运行命令必须使用相应记录指定的工作目录，不能把一个旧 README 的相对路径直接用于另一个版本。

位置	对作者和复现者的用途
`MedRGAG/`	上游及本地 all-Llama 实现、检索语料/索引和部分运行环境；不是整个项目唯一根目录
`MA-RAG/`	外部 MA-RAG 代码；论文中要写实际 intrinsic 设置和记录下来的 patch
`cf_moa/`	五 agent 接口、控制器和采用/扩展实现；历史同名执行计划已多次修订
`Documents/Codex/2026-08-23/https-github-com-xiotakut-cf-mrg/`	较早 CF 实验代码与 Git 历史；用提交定位被覆盖的历史 summary
`Documents/Codex/2026-09-10/benchmark-gzxiong-medrag-sota-baseline-medrag/`	M4/M5 安装、配置与接口来源，后续正式 v5 使用具体运行配置
`Documents/Codex/2026-09-24/cf_moa_rcv_completion_20260924/closeout_20260928/`	两骨干完整六臂的最后分类/来源/格式/区间/成本汇总
`models/LLM-Research-Meta-Llama-3.1-8B-Instruct`、`models/Qwen3-8B`	实际骨干 checkpoint；不能无说明替换另一个同名近似仓库
`models/ncbi-MedCPT-Cross-Encoder`	检索重排模型；checkpoint 不是新方法代码
`docs/`	数据、基线、评价、head、系统和写作的长期主记录
`Documents/Codex/2026-10-03/author_research_dossier/`	本次作者底稿的段稿、来源清单、审阅及导出证据；不是新实验运行

检索范围同样影响比较。MA-RAG 的本地 MedCorp3 由 PubMed、Textbooks、Wikipedia 组成；其当时 StatPearls 文件损坏未采用，不能写 full MedCorp。其他正式配置有各自的完整四库和 BM25/MedCPT 设置。BF16、上下文长度、输出预算、thinking 开关、固定/追加证据、采样次数和 parser 约束都是方法配置的一部分，不应从“都叫 8B 模型”推成资源一致。

历史上发生过包依赖、解码器、JSON grammar、上下文窗口、长输出截断、共享机器排队和 GPU 调度问题。若修复只影响读取速度且输入逐字相等，可记为工程等价；若修复改变生成 schema、停止行为或解码输出，应按新方法版本记录。当前 M4 结构输出修复、MedGENIE 提示版本与 TC-RAG typed 控制正是需要在方法表里保留的实际差别。

162,979 次物理请求及相应 token 账仅属于后期完整 v5 收尾，不是全项目总开销；早期 baseline、开发重试、模型评分与复用有独立记录，一部分历史计时/上游成本未齐全。作者可以报告可归属的分阶段开销，不能将已知一段加总冒充研究总成本，或由显存占满推算有效吞吐。详细配置和运行失败仍以工作区记录及对应方法主记录为准。

7.4 作者现在可以怎样使用这些材料

写引言时，从第一章的研究对象及第六章逻辑链提炼问题与贡献。写数据章节时，采用数据篇的来源、分类、资格和抽样定义，配合实际例子；不要把语义标注和评分资格压成一个“清洗”。写方法时，使用五 head 篇与 CF-MoA 篇的最终采用实现，保留它们如何发展而来的关键决定；把未采用的复杂候选放研发分析。写实验时，先选定层级，再统一该层的样本、配置与评分，引用正文已有完整结果表及其机器来源。

需要解释一个数字时，从该段证据链接定位冻结 summary，再按 ID 进入预测、评分或 trace；必要时由脚本只读重汇总。需要恢复模型推理时，另核对具体版本依赖、模型和检索资产、输入权限与计算预算，不能把本文的阅读版构建命令当实验执行脚本。本文不自动重启任何暂停工作。

作者仍需共同决定：主论文更强调 benchmark 贡献还是系统组织、目标会议与篇幅、当前证据支持的标题强度、是否另行启动最终独立确认。作者姓名/单位、具体责任分工和投稿声明也不能由系统编造。以上是写作和后续研究的真实待决项；已完成的构建、七系统 head 和采用 B 成果仍完整

成立。

八、证据地图：从这份底稿回到原始实验

8.1 哪些文件承担“完整工作汇报”

没有一份旧文档独自覆盖从 08 月复现到 09 月底 CF-MoA 收尾的所有内容。最接近用户所说“不同 agent 每次完成工作汇报”的连续材料，是下面三段相接的记录：

1. 数据构建主记录：最初资源、审阅和后续资格/抽样沿革；其中 1769 行起的 13 阶段回顾覆盖 09-07/08 至早期 v3。
2. R1–R5 全过程报告：2,580 行，148 个研发阶段。R2 为 25 阶段、R3 为 35、R1 为 18、R4 为 30、R5 为 40，包含问题、用户反馈、候选、运行、失败、修复及采用判断。起点已经有 v5，不能拿它替代最初数据工作。
3. CF-MoA 全过程报告：2,054 行，记录 09-21 五 agent 原型至 09-28 全量透明收尾。原 09-23 版本后续补至 16.13 节；较早“未完成”状态要对照后续章节。

本底稿把它们与前史归档、各基线、各 head 和冻结数字联结起来。具体事实完整正文仍只有一个主记录，其他地方是带出处的作者阅读摘要。特别是工程 agent 的聊天进度只说明当时观察，最终分数应由冻结评分或正式收尾报告确认。

8.2 科研主记录的完整导航

以下 29 份是本次覆盖的科研主记录集合；论文写作记录、已有稿件和本底稿另计。`section_register.csv` 建立这些记录初始快照中围栏代码以外的 2,199 个标题索引（写作核验后新增的 R3 更正另见该主记录顶部），以便定位历史段落；标题索引不等于声称逐行重新读过所有正文，更不等于重新运行实验。具体本轮再读范围及前轮审计复用见 coverage 文件。

主记录	内容职责
archive/medrgag_reproduction.md	早期直接回答、论文配置差异与 all-Llama 复现
archive/wm_medrgag.md	85 题 WM 代理、匹配控制及停止结论
archive/cf_wm.md	CF-WM Gate、oracle 撤回、gold-free303 题
archive/cf_method_trials.md	DeltaRev/DeltaRank/CFShift/MoE/RiskRoute 连续探索
archive/cf_residual_adapter.md	paired 四选项 Adapter、跨接口迁移及无协同结论
archive/native_baseline_screening.md	五来源 25,280 输入原生 M0/M1/M2 全量
archive/r1_r5_early_evaluation.md	早期 rubric/自动评分、v2/v3 和互斥展示历史
data/sources.md	26 候选、15 取得、官方资源与许可/缺失状态
data/classification.md	R1–R5 功能定义、正反例与标注边界
data/construction.md	审核纠错、资格、抽样、版本沿革和暴露
baselines/direct_retrieval.md	M0 Direct 与历史 M1 初始检索
baselines/medrgag.md	M2 本地 all-Llama 实现与正式适配
baselines/marag.md	M3 多轮 intrinsic 候选、熵、检索和全量
baselines/medrag.md	M4/M5 检索/输出配置与 M4 结构修复
baselines/imedrag.md	旧 M6 追问流程、失败、成本与暂停
baselines/medgenie.md	当前 M6 生成背景、聊天示例修复与 v2 全量
baselines/tcrag.md	M7 状态控制、异常恢复、typed 组合与消融
evaluation/protocol.md	可见输入、原生评分、分母与精确复用
evaluation/v5.md	当前选用版本、七配置及跨方法比较

主记录	内容职责
research/optimization.md	研究总览、R1wrapper 与跨 head 经验/外部检查
research/r2_support_head.md	支持撤销/补入、规则/事实/范围、全部失败与控制
research/r3_candidate_comparison.md	公开目录、候选读出、校正、来源扩展与失败
research/r4_consequence_head.md	临床 R4、形式/生物探索、给定生理模型局部执行
research/r5_invariance_head.md	F 组合与后续监督/门控/CAD 计划
research/support_update_method.md	跨 R1–R3 的论文机制论证和贡献边界
research/support_update_experiment_report.md	R1–R5 148 阶段全过程回顾
research/cf_moa.md	五 agent、路由、聚合、B、RCV 及收尾的持续主记录
research/cf_moa_experiment_report.md	CF-MoA 按版本和执行轮次的全过程回顾
workspace.md	代码/模型/环境位置、公共性能修复、文档和发布沿革

8.3 已冻结的机器证据和定位顺序

要核对的对象	最直接证据	继续下钻的方向
26/15/55,991 及 v4/v5 计数	benchmark_contribution_audit.json	原 manifest、去向 CSV、目标 JSONL、抽样 frame 与 replay 脚本；包含 33 个原文件哈希
七配置 42 指标和输入集合	seven_methods_audit.json	正式 category_comparison.csv 和原评分 JSONL；已有只读重汇总核验
七系统 21 组 head 与对照	head_research_audit.json	各原方法输出、head 输出、评分、类别交集和原请求复用账
五角色真实实现与默认 B	five_agent_framework_audit.json	controller/agent 源代码、原 09-21 计划与 09-23 修订、123 消融及完整结果
历史方向与 148 阶段覆盖	research_path_audit.json	原始用户会话定位、阶段目录与决定结果、全过程主记录
后期六臂全量和区间	09-28 收尾目录	all_category_results、all_source_results、format_input_results、pair_summary、family_effect_intervals 及费用原件
本次底稿如何合成与检查	本轮证据目录	document_inventory、section_register、head_stage_register、段稿 coverage、独立审阅与编译收据

每个数字至少绑定方法/臂、数据版本、评价范围、评分指标和来源。需要重现一张图时，读取已保存汇总并核对输入哈希；需要核对某个结论时，进一步检查逐例修复/误伤与原生评分；需要复跑模型时，再检查模型、语料、任务合同、参数和实际源码。仅保存一个 summary 而没有可追溯输入不能证明原始推理已可重现；本项目保留的是多层证据，部分受来源访问和大型模型/索引依赖限制。

8.4 这次整理本身做了什么

本次从现有科研主记录建立完整目录，三条并行整理线分别负责数据、七基线/五 head、CF-MoA 过程；主任务补齐前史、跨版本术语、全局因果链和作者取舍。148 个 head 阶段另有带原文开头

节选的 CSV 导航，方便作者查找具体尝试。源数据哈希、原实验总结和上次数值审计复用均有记录。新增的是文档、索引、导出和审阅，没有修改预测、标签、评分、采样成员或方法代码。

作者阅读版的中文 Markdown 是本底稿的协作源；同时提供由该文导出的 LaTeX 和 PDF，便于离线批注。这是研究资料的排版导出，不能误称为重新完成了一篇英文论文或产生了新实验。既有英文 main.tex 和 framework.tex 保留各自身份。